林轩田《机器学习基石》课程笔记7 -- The VC Dimension

作者: 红色石头 公众号: Al有道 (id: redstonewill)

前几节课着重介绍了机器能够学习的条件并做了详细的推导和解释。机器能够学习必须满足两个条件:

- 假设空间H的Size M是有限的,即当N足够大的时候,那么对于假设空间中任意一个假设g, $E_{out} pprox E_{in}$ 。
- 利用算法A从假设空间H中,挑选一个g,使 $E_{in}(g)pprox 0$,则 $E_{out}pprox 0$ 。

这两个条件,正好对应着test和trian两个过程。train的目的是使损失期望 $E_{in}(g)pprox 0$;test的目的是使将算法用到新的样本时的损失期望也尽可能小,即 $E_{out}pprox 0$ 。

正因为如此,上次课引入了break point,并推导出只要break point存在,则M有上界,一定存在 $E_{out}pprox E_{in}$ 。

本次笔记主要介绍VC Dimension的概念。同时也是总结VC Dimension与 $E_{in}(g)pprox 0$, $E_{out}pprox 0$,Model Complexity Penalty(下面会讲到)的关系。

— Definition of VC Dimension

首先,我们知道如果一个假设空间H有break point k,那么它的成长函数是有界的,它的上界称为Bound function。根据数学归纳法,Bound function也是有界的,且上界为 N^{k-1} 。从下面的表格可以看出,N(k-1)比B(N,k)松弛很多。

$$m_{\mathcal{H}}(N)$$
 of break point $k \leq B(N, k) = \underbrace{\sum_{i=0}^{k-1} \binom{N}{i}}_{\text{highest term } N^{k-1}}$

provably & loosely, for
$$N \ge 2, k \ge 3$$
,
$$m_{\mathcal{H}}(N) \le B(N, k) = \sum_{i=0}^{k-1} \binom{N}{i} \le N^{k-1}$$

则根据上一节课的推导, VC bound就可以转换为:

For any
$$g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$$
 and 'statistical' large \mathcal{D} , for $N \geq 2$, $k \geq 3$

$$\mathbb{P}_{\mathcal{D}} \Big[\big| E_{\text{in}}(g) - E_{\text{out}}(g) \big| > \epsilon \Big]$$

$$\leq \mathbb{P}_{\mathcal{D}} \Big[\exists h \in \mathcal{H} \text{ s.t. } \big| E_{\text{in}}(h) - E_{\text{out}}(h) \big| > \epsilon \Big]$$

$$\leq 4m_{\mathcal{H}}(2N) \exp \Big(-\frac{1}{8} \epsilon^2 N \Big)$$
if $k \text{ exists} \atop \leq 4(2N)^{k-1} \exp \Big(-\frac{1}{8} \epsilon^2 N \Big)$

这样,不等式只与k和N相关了,一般情况下样本N足够大,所以我们只考虑k值。有如下结论:

- 若假设空间H有break point k, 且N足够大,则根据VC bound理论,算法有良好的泛化能力
- 在假设空间中选择一个矩g,使 $E_{in}pprox 0$,则其在全集数据中的错误率会较低

if $\bigcirc m_{\mathcal{H}}(N)$ breaks at k (good \mathcal{H})

2 N large enough (good \mathcal{D}) \Longrightarrow probably generalized ' $E_{\text{out}} \approx E_{\text{in}}$ ', and if $\bigcirc A$ picks a g with small E_{in} (good A) \Longrightarrow probably learned! (:-) good luck)

下面介绍一个新的名词: VC Dimension。VC Dimension就是某假设集H能够shatter的最多inputs的个数,即最大完全正确的分类能力。(注意,只要存在一种分布的inputs能够正确分类也满足)。

shatter的英文意思是"粉碎",也就是说对于inputs的所有情况都能列举出来。例如对N个输入,如果能够将 $\mathbf{2}^N$ 种情况都列出来,则称该N个输入能够被假设集H shatter。

根据之前break point的定义:假设集不能被shatter任何分布类型的inputs的最少个数。则VC Dimension等于break point的个数减一。

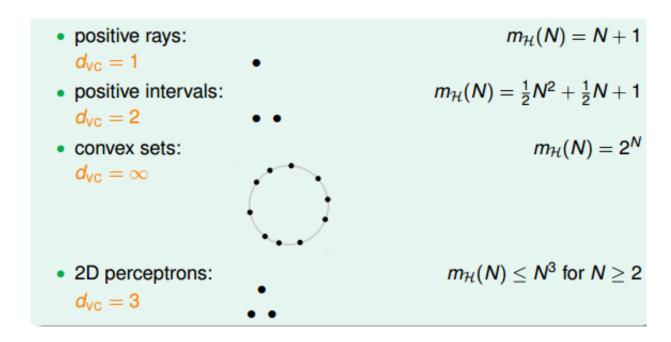
Definition

VC dimension of \mathcal{H} , denoted $d_{VC}(\mathcal{H})$ is

largest N for which $m_{\mathcal{H}}(N) = 2^N$

- the most inputs \mathcal{H} that can shatter
- d_{VC} = 'minimum k' 1

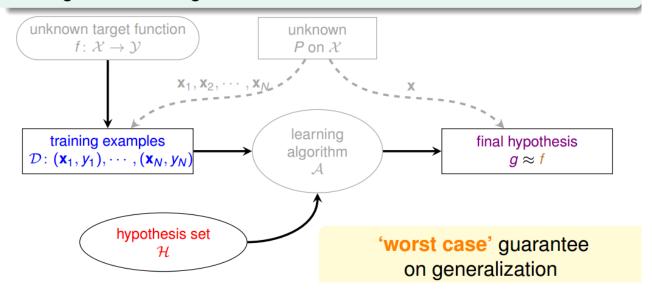
现在,我们回顾一下之前介绍的四种例子,它们对应的VC Dimension是多少:



用 d_{vc} 代替k,那么VC bound的问题也就转换为与 d_{vc} 和N相关了。同时,如果一个假设集H的 d_{vc} 确定了,则就能满足机器能够学习的第一个条件 $E_{out} \approx E_{in}$,与算法、样本数据分布和目标函数都没有关系。

finite $d_{ extsf{VC}} \Longrightarrow g$ 'will' generalize ($E_{ extsf{out}}(g) pprox E_{ extsf{in}}(g)$)

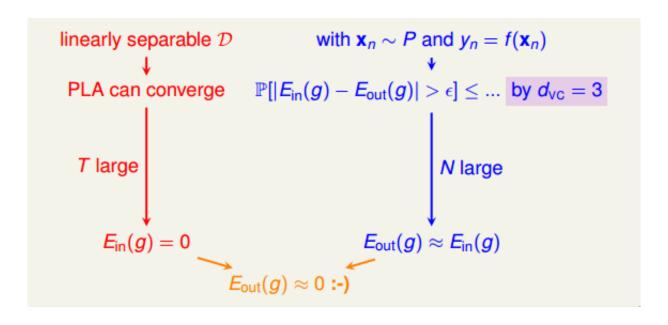
- ullet regardless of learning algorithm ${\cal A}$
- regardless of input distribution P
- regardless of target function f



二、VC Dimension of Perceptrons

回顾一下我们之前介绍的2D下的PLA算法,已知Perceptrons的k=4,即 $d_{vc}=3$ 。根据VC Bound理论,当N足够大的时候, $E_{out}(g) pprox E_{in}(g)$ 。如果找到一个g,使

 $E_{in}(g)pprox 0$,那么就能证明PLA是可以学习的。



这是在2D情况下,那如果是多维的Perceptron,它对应的 d_{vc} 又等于多少呢?

已知在1D Perceptron, $d_{vc}=2$,在2D Perceptrons, $d_{vc}=3$,那么我们有如下假设: $d_{vc}=d+1$,其中d为维数。

要证明的话,只需分两步证明:

- $d_{vc} \geq d+1$
- $d_{vc} \leq d+1$
 - 1D perceptron (pos/neg rays): d_{VC} = 2
 - 2D perceptrons: d_{VC} = 3
 - d_{vc} ≥ 3:
 - d_{vc} ≤ 3: × ° ×
 - *d*-D perceptrons: $d_{VC} \stackrel{?}{=} d + 1$

首先证明第一个不等式: $d_{vc} \geq d+1$ 。

在d维里,我们只要找到某一类的d+1个inputs可以被shatter的话,那么必然得到 $d_{vc} \geq d+1$ 。所以,我们有意构造一个d维的矩阵X能够被shatter就行。X是d维的,有d+1个inputs,每个inputs加上第零个维度的常数项1,得到X的矩阵:

$$X = \begin{bmatrix} -\mathbf{x}_{1}^{T} - \\ -\mathbf{x}_{2}^{T} - \\ -\mathbf{x}_{3}^{T} - \\ \vdots \\ -\mathbf{x}_{d+1}^{T} - \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ 1 & 0 & 1 & & 0 \\ \vdots & \vdots & & \ddots & 0 \\ 1 & 0 & \dots & 0 & 1 \end{bmatrix}$$

矩阵中,每一行代表一个inputs,每个inputs是d+1维的,共有d+1个inputs。这里构造的X很明显是可逆的。shatter的本质是假设空间H对X的所有情况的判断都是对的,即总能找到权重W,满足X*W=y, $W=X^{-1}*y$ 。由于这里我们构造的矩阵X的逆矩阵存在,那么d维的所有inputs都能被shatter,也就证明了第一个不等式。

$$\mathbf{X} = \begin{bmatrix} & -\mathbf{x}_1^T - \\ & -\mathbf{x}_2^T - \\ & \vdots \\ & -\mathbf{x}_{d+1}^T - \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & & \ddots & 0 \\ 1 & 0 & \dots & 0 & 1 \end{bmatrix} \text{ invertible}$$

for any
$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_{d+1} \end{bmatrix}$$
, find \mathbf{w} such that
$$\operatorname{sign}(\mathbf{X}\mathbf{w}) = \mathbf{y} \iff (\mathbf{X}\mathbf{w}) = \mathbf{y} \overset{\mathrm{X} \text{ invertible!}}{\Longleftrightarrow} \mathbf{w} = \mathbf{X}^{-1}\mathbf{y}$$

然后证明第二个不等式: $d_{vc} \leq d+1$.

在d维里,如果对于任何的d+2个inputs,一定不能被shatter,则不等式成立。我们构造一个任意的矩阵X,其包含d+2个inputs,该矩阵有d+1列,d+2行。这d+2个向量的某一列一定可以被另外d+1个向量线性表示,例如对于向量 X_{d+2} ,可表示为:

$$X_{d+2} = a_1 * X_1 + a_2 * X_2 + \cdots + a_d * X_d$$

其中,假设 $a_1 > 0$, $a_2, \dots, a_d < 0$.

那么如果 X_1 是正类, X_2,\cdots,X_d 均为负类,则存在W,得到如下表达式: $X_{d+2}*W=a_1*X_1*W+a_2*X_2*W+\cdots+a_d*X_d*W>0$

因为其中蓝色项大于0,代表正类;红色项小于0,代表负类。所有对于这种情况,

 X_d+2 一定是正类,无法得到负类的情况。也就是说,d+2个inputs无法被shatter。证明完毕!

d-D General Case

$$X = \begin{bmatrix} & -\mathbf{x}_1^T - \\ & -\mathbf{x}_2^T - \\ & \vdots \\ & -\mathbf{x}_{d+1}^T - \\ & -\mathbf{x}_{d+2}^T - \end{bmatrix}$$

more rows than columns:

linear dependence (some a_i non-zero) $\mathbf{x}_{d+2} = \mathbf{a}_1 \mathbf{x}_1 + \mathbf{a}_2 \mathbf{x}_2 + \ldots + \mathbf{a}_{d+1} \mathbf{x}_{d+1}$

• can you generate $(sign(a_1), sign(a_2), ..., sign(a_{d+1}), \times)$? if so, what **w**?

$$\mathbf{w}^{T}\mathbf{x}_{d+2} = \mathbf{a}_{1} \underbrace{\mathbf{w}^{T}\mathbf{x}_{1}}_{\circ} + \mathbf{a}_{2} \underbrace{\mathbf{w}^{T}\mathbf{x}_{2}}_{\times} + \dots + \mathbf{a}_{d+1} \underbrace{\mathbf{w}^{T}\mathbf{x}_{d+1}}_{\times}$$

$$> 0 \text{(contradition!)}$$

综上证明可得 $d_{vc}=d+1$ 。

三、Physical Intuition VC Dimension

- hypothesis parameters $\mathbf{w} = (w_0, w_1, \dots, w_d)$: creates degrees of freedom
- hypothesis quantity $M = |\mathcal{H}|$: 'analog' degrees of freedom
- hypothesis 'power' d_{VC} = d + 1:
 effective 'binary' degrees of freedom

$d_{VC}(\mathcal{H})$: powerfulness of \mathcal{H}

上节公式中W又名features,即自由度。自由度是可以任意调节的,如同上图中的旋钮一样,可以调节。VC Dimension代表了假设空间的分类能力,即反映了H的自由度,产生dichotomy的数量,也就等于features的个数,但也不是绝对的。

practical rule of thumb:

$d_{VC} \approx \#$ free parameters (but not always)

例如,对2D Perceptrons,线性分类, $d_{vc}=3$,则 $W=\{w_0,w_1,w_2\}$,也就是说只要3个features就可以进行学习,自由度为3。

介绍到这,我们发现M与 d_{vc} 是成正比的,从而得到如下结论:

M and d_{VC}

copied from Lecture 5:-)

- 1 can we make sure that $E_{out}(g)$ is close enough to $E_{in}(g)$?
- 2 can we make $E_{in}(g)$ small enough?

small M

- Yes!,
 P[BAD] ≤ 2 ⋅ M ⋅ exp(...)
- 2 No!, too few choices

large M

- 1 No!, $\mathbb{P}[\mathbf{BAD}] \leq 2 \cdot \mathbf{M} \cdot \exp(\ldots)$
- 2 Yes!, many choices

small d_{VC}

- 1 Yes!, $\mathbb{P}[BAD] \le 4 \cdot (2N)^{d_{VC}} \cdot \exp(...)$
- No!, too limited power

large d_{VC}

- 1 No!, $\mathbb{P}[BAD] \le 4 \cdot (2N)^{d_{VC}} \cdot \exp(...)$
- Yes!, lots of power

四、Interpreting VC Dimension

下面,我们将更深入地探讨VC Dimension的意义。首先,把VC Bound重新写到这里:

For any
$$g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$$
 and 'statistical' large \mathcal{D} , for $N \geq 2$, $d_{VC} \geq 2$

$$\mathbb{P}_{\mathcal{D}}\left[\left|E_{\text{in}}(g) - E_{\text{out}}(g)\right| > \epsilon\right] \leq \underbrace{4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2N\right)}_{\delta}$$

根据之前的泛化不等式,如果 $|E_{in}-E_{out}|>\epsilon$,即出现bad坏的情况的概率最大不超过 δ 。那么反过来,对于good好的情况发生的概率最小为 $1-\delta$,则对上述不等式进行重新推导:

Rephrase

$$\begin{array}{lll} \ldots, \text{ with probability} \geq 1 - \delta, \, \textbf{GOOD} \colon \left| E_{\text{in}}(g) - E_{\text{out}}(g) \right| \leq \epsilon \\ \\ \text{set} & \delta & = & 4(2N)^{d_{\text{VC}}} \exp\left(-\frac{1}{8}\epsilon^2N\right) \\ \\ \frac{\delta}{4(2N)^{d_{\text{VC}}}} & = & \exp\left(-\frac{1}{8}\epsilon^2N\right) \\ \\ \ln\left(\frac{4(2N)^{d_{\text{VC}}}}{\delta}\right) & = & \frac{1}{8}\epsilon^2N \\ \\ \sqrt{\frac{8}{N}\ln\left(\frac{4(2N)^{d_{\text{VC}}}}{\delta}\right)} & = & \epsilon \\ \end{array}$$

 ϵ 表现了假设空间H的泛化能力, ϵ 越小,泛化能力越大。

 $\Omega(N, \mathcal{H}, \delta)$

For any
$$g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$$
 and 'statistical' large \mathcal{D} , for $N \geq 2$, $d_{VC} \geq 2$

$$\mathbb{P}_{\mathcal{D}}\Big[\underbrace{\left|E_{\text{in}}(g) - E_{\text{out}}(g)\right| > \epsilon}\Big] \qquad \leq \qquad \underbrace{4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2N\right)}_{\delta}$$

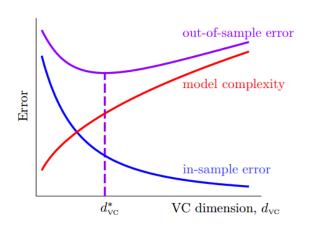
Rephrase ..., with probability $\geq 1 - \delta$, GOOD! gen. error $\left| E_{\text{in}}(g) - E_{\text{out}}(g) \right| \leq \sqrt{\frac{8}{N} \ln \left(\frac{4(2N)^{d_{VC}}}{\delta} \right)}$ $\leq E_{\text{in}}(g) - \sqrt{\frac{8}{N} \ln \left(\frac{4(2N)^{d_{VC}}}{\delta} \right)} \leq E_{\text{out}}(g) \leq E_{\text{in}}(g) + \sqrt{\frac{8}{N} \ln \left(\frac{4(2N)^{d_{VC}}}{\delta} \right)}$ $\leq \text{penalty for model complexity}$

至此,已经推导出泛化误差 E_{out} 的边界,因为我们更关心其上界(E_{out} 可能的最大值),即:

with a high probability,

$$E_{\mathsf{out}}(g) \leq E_{\mathsf{in}}(g) + \underbrace{\sqrt{\frac{8}{N} \mathsf{ln}\left(\frac{4(2N)^{d_{\mathsf{VC}}}}{\delta}\right)}}_{\Omega(N,\mathcal{H},\delta)}$$

上述不等式的右边第二项称为模型复杂度,其模型复杂度与样本数量N、假设空间H(d_{vc})、 ϵ 有关。 E_{out} 由 E_{in} 共同决定。下面绘出 E_{out} 、model complexity、 E_{in} 随 d_{vc} 变化的关系:



- d_{VC} ↑: E_{in} ↓ but Ω ↑
- d_{VC} ↓: Ω ↓ but E_{in} ↑
- best d^{*}_{VC} in the middle

powerful \mathcal{H} not always good!

通过该图可以得出如下结论:

- d_{vc} 越大, E_{in} 越小, Ω 越大 (复杂) 。
- d_{vc} 越小, E_{in} 越大, Ω 越小 (简单) 。
- 随着 d_{vc} 增大, E_{out} 会先减小再增大。

所以,为了得到最小的 E_{out} ,不能一味地增大 d_{vc} 以减小 E_{in} ,因为 E_{in} 太小的时候,模型复杂度会增加,造成 E_{out} 变大。也就是说,选择合适的 d_{vc} ,选择的features个数要合适。

下面介绍一个概念:样本复杂度(Sample Complexity)。如果选定 d_{vc} ,样本数据D选择多少合适呢?通过下面一个例子可以帮助我们理解:

given specs
$$\epsilon=0.1,\,\delta=0.1,\,d_{\text{VC}}=3,\,$$
 want $4(2N)^{d_{\text{VC}}}\exp\left(-\frac{1}{8}\epsilon^2N\right)\leq\delta$ $\frac{N}{100}$ bound $\frac{N}{100}$ sample complexity: sample complexity: $10,000$ 1.19×10^8 need $N\approx10,000d_{\text{VC}}$ in theory $100,000$ 1.65×10^{-38} $29,300$ 9.99×10^{-2}

通过计算得到N=29300,刚好满足 $\delta=0.1$ 的条件。N大约是 d_{vc} 的10000倍。这个数值太大了,实际中往往不需要这么多的样本数量,大概只需要 d_{vc} 的10倍就够了。N的理论值之所以这么大是因为VC Bound 过于宽松了,我们得到的是一个比实际大得多的上界。

Looseness of VC Bound

$$\mathbb{P}_{\mathcal{D}} \Big[\big| E_{\mathsf{in}}(g) - E_{\mathsf{out}}(g) \big| > \epsilon \Big] \leq 4(2N)^{d_{\mathsf{VC}}} \exp \left(-\frac{1}{8} \epsilon^2 N \right)$$

theory: $N \approx 10,000 d_{VC}$; practice: $N \approx 10 d_{VC}$

Why?

Hoeffding for unknown E_{out}

• $m_{\mathcal{H}}(N)$ instead of $|\mathcal{H}(\mathbf{x}_1,\ldots,\mathbf{x}_N)|$

• $N^{d_{VC}}$ instead of $m_{\mathcal{H}}(N)$

union bound on worst cases

any distribution, any target

'any' data

'any' ${\cal H}$ of same $d_{{
m VC}}$

any choice made by $\ensuremath{\mathcal{A}}$

—but hardly better, and 'similarly loose for all models'

值得一提的是,VC Bound是比较宽松的,而如何收紧它却不是那么容易,这也是机器学习的一大难题。但是,令人欣慰的一点是,VC Bound基本上对所有模型的宽松程度是基本一致的,所以,不同模型之间还是可以横向比较。从而,VC Bound宽松对机器学习的可行性还是没有太大影响。

五、总结

本节课主要介绍了VC Dimension的概念就是最大的non-break point。然后,我们得到了Perceptrons在d维度下的VC Dimension是d+1。接着,我们在物理意义上,将 d_{vc} 与自由度联系起来。最终得出结论 d_{vc} 不能过大也不能过小。选取合适的值,才能让 E_{out} 足够小,使假设空间H具有良好的泛化能力。

注明:

文章中所有的图片均来自台湾大学林轩田《机器学习基石》课程