林轩田《机器学习基石》课程笔记9 -- Linear Regression

作者: 红色石头 公众号: Al有道 (id: redstonewill)

上节课,我们主要介绍了在有noise的情况下,VC Bound理论仍然是成立的。同时,介绍了不同的error measure方法。本节课介绍机器学习最常见的一种算法: Linear Regression.

一、线性回归问题

在之前的Linear Classification课程中,讲了信用卡发放的例子,利用机器学习来决定是否给用户发放信用卡。本节课仍然引入信用卡的例子,来解决给用户发放信用卡额度的问题,这就是一个线性回归(Linear Regression)问题。

Linear Regression Hypothesis

age	23 years
annual salary	NTD 1,000,000
year in job	0.5 year
current debt	200,000

• For $\mathbf{x} = (x_0, x_1, x_2, \dots, x_d)$ 'features of customer', approximate the desired credit limit with a weighted sum:

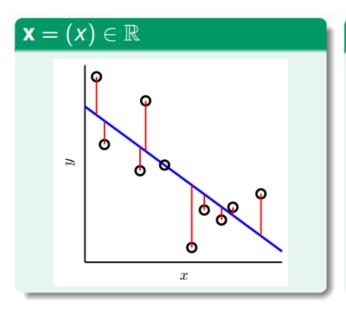
$$y \approx \sum_{i=0}^d \mathbf{w}_i x_i$$

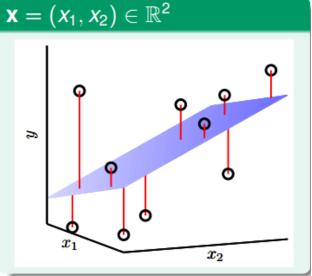
• linear regression hypothesis: $h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$

 $h(\mathbf{x})$: like perceptron, but without the sign

令用户特征集为d维的X,加上常数项,维度为d+1,与权重w的线性组合即为 Hypothesis,记为h(x)。线性回归的预测函数取值在整个实数空间,这跟线性分类不

$$h(x) = w^T X$$





linear regression: find lines/hyperplanes with small residuals

根据上图,在一维或者多维空间里,线性回归的目标是找到一条直线(对应一维)、 一个平面(对应二维)或者更高维的超平面,使样本集中的点更接近它,也就是残留 误差Residuals最小化。

一般最常用的错误测量方式是基于最小二乘法,其目标是计算误差的最小平方和对应 的权重w, 即上节课介绍的squared error:

popular/historical error measure:

squared error
$$err(\hat{y}, y) = (\hat{y} - y)^2$$

in-sample

$$E_{\text{in}}(h\mathbf{w}) = \frac{1}{N} \sum_{n=1}^{N} \underbrace{\left(\frac{h(\mathbf{x}_n)}{\mathbf{w}^T \mathbf{x}_n} - y_n\right)^2}_{\mathbf{w}^T \mathbf{x}_n} \qquad E_{\text{out}}(\mathbf{w}) = \underbrace{\mathcal{E}}_{(\mathbf{x}, y) \sim P} (\mathbf{w}^T \mathbf{x} - y)^2$$

out-of-sample

$$E_{\text{out}}(\mathbf{w}) = \underset{(\mathbf{x},y)\sim P}{\mathcal{E}} (\mathbf{w}^T \mathbf{x} - y)^2$$

这里提一点,最小二乘法可以解决线性问题和非线性问题。线性最小二乘法的解是 closed-form,即 $X=(A^TA)^{-1}A^Ty$,而非线性最小二乘法没有closed-form,通常 用迭代法求解。本节课的解就是closed-form的。关于最小二乘法的一些介绍,请参见我的另一篇博文:

最小二乘法和梯度下降法的一些总结

二、线性回归算法

样本数据误差 E_{in} 是权重w的函数,因为X和y都是已知的。我们的目标就是找出合适的w,使 E_{in} 能够最小。那么如何计算呢?

首先,运用矩阵转换的思想,将 E_{in} 计算转换为矩阵的形式。

$$E_{in}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^{N} (\mathbf{w}^{T} \mathbf{x}_{n} - y_{n})^{2} = \frac{1}{N} \sum_{n=1}^{N} (\mathbf{x}_{n}^{T} \mathbf{w} - y_{n})^{2}$$

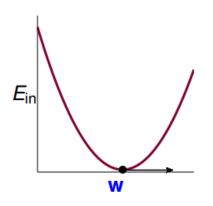
$$= \frac{1}{N} \left\| \begin{array}{c} \mathbf{x}_{1}^{T} \mathbf{w} - y_{1} \\ \mathbf{x}_{2}^{T} \mathbf{w} - y_{2} \\ \dots \\ \mathbf{x}_{N}^{T} \mathbf{w} - y_{N} \end{array} \right\|^{2}$$

$$= \frac{1}{N} \left\| \begin{bmatrix} --\mathbf{x}_{1}^{T} - - \\ --\mathbf{x}_{2}^{T} - - \\ \dots \\ --\mathbf{x}_{N}^{T} - - \end{bmatrix} \mathbf{w} - \begin{bmatrix} y_{1} \\ y_{2} \\ \dots \\ y_{N} \end{bmatrix} \right\|^{2}$$

$$= \frac{1}{N} \left\| \underbrace{\mathbf{X}}_{N \times d+1} \underbrace{\mathbf{w}}_{d+1 \times 1} - \underbrace{\mathbf{y}}_{N \times 1} \right\|^{2}$$

然后,对于此类线性回归问题, $E_{in}(w)$ 一般是个凸函数。凸函数的话,我们只要找到一阶导数等于零的位置,就找到了最优解。那么,我们将 E_w 对每个 $w_i,i=0,1,\cdots,d$ 求偏导,偏导为零的 w_i ,即为最优化的权重值分布。

$$\min_{\mathbf{w}} E_{in}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$



- E_{in}(w): continuous, differentiable, convex
- necessary condition of 'best' w

$$\nabla E_{\text{in}}(\mathbf{w}) \equiv \begin{bmatrix} \frac{\partial E_{\text{in}}}{\partial w_0}(\mathbf{w}) \\ \frac{\partial E_{\text{in}}}{\partial w_1}(\mathbf{w}) \\ \dots \\ \frac{\partial E_{\text{in}}}{\partial w_n}(\mathbf{w}) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix}$$

—not possible to 'roll down'

task: find \mathbf{w}_{LIN} such that $\nabla E_{in}(\mathbf{w}_{LIN}) = \mathbf{0}$

根据梯度的思想,对 E_w 进行矩阵话求偏导处理:

The Gradient $\nabla E_{in}(\mathbf{w})$

$$E_{in}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{N} \left(\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2 \mathbf{w}^T \mathbf{X}^T \mathbf{y} + \mathbf{y}^T \mathbf{y} \right)$$

one w only

$$E_{in}(w) = \frac{1}{N} \left(aw^2 - 2bw + c \right)$$

$$\nabla E_{in}(w) = \frac{1}{N} \left(2aw - 2b \right)$$

simple! :-)

vector w

$$E_{in}(\mathbf{w}) = \frac{1}{N} \left(\mathbf{w}^T \mathbf{A} \mathbf{w} - 2 \mathbf{w}^T \mathbf{b} + c \right)$$
$$\nabla E_{in}(\mathbf{w}) = \frac{1}{N} \left(2\mathbf{A} \mathbf{w} - 2\mathbf{b} \right)$$

similar (derived by definition)

$$\nabla E_{\mathsf{in}}(\mathbf{w}) = \frac{2}{N} \left(\mathbf{X}^\mathsf{T} \mathbf{X} \mathbf{w} - \mathbf{X}^\mathsf{T} \mathbf{y} \right)$$

令偏导为零,最终可以计算出权重向量w为:

Optimal Linear Regression Weights

task: find \mathbf{w}_{LIN} such that $\frac{2}{N} \left(\mathbf{X}^{\mathsf{T}} \mathbf{X} \mathbf{w} - \mathbf{X}^{\mathsf{T}} \mathbf{y} \right) = \nabla E_{in}(\mathbf{w}) = \mathbf{0}$

invertible X^TX

· easy! unique solution

$$\mathbf{w}_{LIN} = \underbrace{\left(\mathbf{X}^{T}\mathbf{X}\right)^{-1}\mathbf{X}^{T}}_{pseudo-inverse} \mathbf{y}$$

often the case because

$$N \gg d + 1$$

singular X^TX

- many optimal solutions
- · one of the solutions

$$\mathbf{w}_{\mathsf{LIN}} = \mathbf{X}^{\dagger} \mathbf{y}$$

by defining X[†] in other ways

practical suggestion:

use well-implemented \dagger routine instead of $(\mathbf{X}^T\mathbf{X})^{-1}\,\mathbf{X}^T$ for numerical stability when almost-singular

最终,我们推导得到了权重向量 $w=(X^TX)^{-1}X^Ty$,这是上文提到的closed-form解。其中, $(X^TX)^{-1}X^T$ 又称为伪逆矩阵pseudo-inverse,记为 X^+ ,维度是(d+1)xN。

但是,我们注意到,伪逆矩阵中有逆矩阵的计算,逆矩阵 $(X^TX)^{-1}$ 是否一定存在?一般情况下,只要满足样本数量N远大于样本特征维度d+1,就能保证矩阵的逆是存在的,称之为非奇异矩阵。但是如果是奇异矩阵,不可逆怎么办呢?其实,大部分的计算逆矩阵的软件程序,都可以处理这个问题,也会计算出一个逆矩阵。所以,一般伪逆矩阵是可解的。

三、泛化问题

现在,可能有这样一个疑问,就是这种求解权重向量的方法是机器学习吗?或者说这种方法满足我们之前推导VC Bound,即是否泛化能力强 $E_{in} pprox E_{out}$?

Is Linear Regression a 'Learning Algorithm'?

$$\mathbf{w}_{\text{LIN}} = \mathbf{X}^{\dagger} \mathbf{y}$$

No!

- analytic (closed-form) solution, 'instantaneous'
- not improving E_{in} nor E_{out} iteratively

Yes!

- good E_{in}?
 yes, optimal!
- good E_{out}?
 yes, finite d_{VC} like perceptrons
- improving iteratively?
 somewhat, within an iterative pseudo-inverse routine

if $E_{out}(\mathbf{w}_{LIN})$ is good, learning 'happened'!

有两种观点: 1、这不属于机器学习范畴。因为这种closed-form解的形式跟一般的机器学习算法不一样,而且在计算最小化误差的过程中没有用到迭代。2、这属于机器学习范畴。因为从结果上看, E_{in} 和 E_{out} 都实现了最小化,而且实际上在计算逆矩阵的过程中,也用到了迭代。

其实,只从结果来看,这种方法的确实现了机器学习的目的。下面通过介绍一种更简单的方法,证明linear regression问题是可以通过线下最小二乘法方法计算得到好的 E_{in} 和 E_{out} 的。

Benefit of Analytic Solution: 'Simpler-than-VC' Guarantee

$$\overline{E_{\text{in}}} = \underbrace{\mathcal{E}}_{\mathcal{D} \sim P^N} \Big\{ E_{\text{in}}(\mathbf{w}_{\text{LIN}} \text{ w.r.t. } \mathcal{D}) \Big\}^{\text{to be shown}} \text{ noise level} \cdot (1 - \frac{d+1}{N})$$

$$E_{\text{in}}(\mathbf{w}_{\text{LIN}}) = \frac{1}{N} \|\mathbf{y} - \underbrace{\hat{\mathbf{y}}}_{\text{predictions}}\|^2 = \frac{1}{N} \|\mathbf{y} - \underbrace{\mathbf{X}}_{\mathbf{w}_{\text{LIN}}}^{\dagger} \mathbf{y}\|^2$$

$$= \frac{1}{N} \|(\underbrace{\mathbf{J}}_{\text{identity}} - \mathbf{X} \mathbf{X}^{\dagger}) \mathbf{y}\|^2$$

call XX^{\dagger} the hat matrix H because it puts \land on y

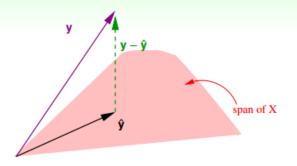
首先,我们根据平均误差的思想,把 $E_{in}(w_{LIN})$ 写成如图的形式,经过变换得到:

$$|E_{in}(w_{LIN}) = rac{1}{N} ||(I - XX^+)y||^2 = rac{1}{N} ||(I - H)y||^2$$

我们称 XX^+ 为帽子矩阵,用H表示。

下面从几何图形的角度来介绍帽子矩阵H的物理意义。

Geometric View of Hat Matrix



in \mathbb{R}^N

- ŷ = Xw_{LIN} within the span of X columns
- $y \hat{y}$ smallest: $y \hat{y} \perp span$
- H: project y to ŷ ∈ span
- I H: transform y to y $\hat{y} \perp$ span

claim: trace(I - H) = N - (d + 1). Why? :-)

图中,y是N维空间的一个向量,粉色区域表示输入矩阵X乘以不同权值向量w所构成的空间,根据所有w的取值,预测输出都被限定在粉色的空间中。向量 \hat{y} 就是粉色空间中的一个向量,代表预测的一种。y是实际样本数据输出值。

机器学习的目的是在粉色空间中找到一个 \hat{y} ,使它最接近真实的y,那么我们只要将y在粉色空间上作垂直投影即可,投影得到的 \hat{y} 即为在粉色空间内最接近y的向量。这样即使平均误差 \overline{E} 最小。

从图中可以看出, \hat{y} 是y的投影,已知 $\hat{y}=Hy$,那么H表示的就是将y投影到 \hat{y} 的一种操作。图中绿色的箭头 $y-\hat{y}$ 是向量y与 \hat{y} 相减, $y-\hat{y}$ 垂直于粉色区域。已知 $(I-H)y=y-\hat{y}$ 那么I-H表示的就是将y投影到 $y-\hat{y}$ 即垂直于粉色区域的一种操作。这样的话,我们就赋予了H和I-H不同但又有联系的物理意义。

这里trace(I-H)称为I-H的迹,值为N-(d+1)。这条性质很重要,一个矩阵的 trace等于该矩阵的所有特征值(Eigenvalues)之和。下面给出简单证明:

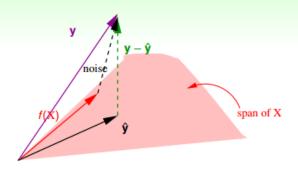
$$egin{aligned} trace(I-H) &= trace(I) - trace(H) \ &= N - trace(XX^+) = N - trace(X(X^TX)^{-1}X^T \ &= N - trace(X^TX(X^TX)^{-1}) = N - trace(I_{d+1} \ &= N - (d+1) \end{aligned}$$

介绍下该I-H这种转换的物理意义:原来有一个有N个自由度的向量y,投影到一个有d+1维的空间x(代表一列的自由度,即单一输入样本的参数,如图中粉色区域),而

余数剩余的自由度最大只有N-(d+1)种。

在存在noise的情况下,上图变为:

An Illustrative 'Proof'



- if y comes from some ideal $f(X) \in \text{span}$ plus **noise**
- noise transformed by I − H to be y − ŷ

$$\begin{aligned} E_{\text{in}}(\mathbf{w}_{\text{LIN}}) &= \frac{1}{N} \|\mathbf{y} - \hat{\mathbf{y}}\|^2 &= \frac{1}{N} \|(\mathbf{I} - \mathbf{H}) \mathbf{noise}\|^2 \\ &= \frac{1}{N} (N - (d+1)) \|\mathbf{noise}\|^2 \end{aligned}$$

$$\overline{E_{\text{in}}} = \text{noise level} \cdot \left(1 - \frac{d+1}{N}\right)$$
 $\overline{E_{\text{out}}} = \text{noise level} \cdot \left(1 + \frac{d+1}{N}\right) \text{ (complicated!)}$

图中,粉色空间的红色箭头是目标函数f(x),虚线箭头是noise,可见,真实样本输出y由f(x)和noise相加得到。由上面推导,已知向量y经过I-H转换为 $y-\hat{y}$,而noise与y是线性变换关系,那么根据线性函数知识,我们推导出noise经过I-H也能转换为 $y-\hat{y}$ 。则对于样本平均误差,有下列推导成立:

$$E_{in}(w_{LIN}) = rac{1}{N} ||y - \hat{y}||^2 = rac{1}{N} ||(I - H)noise||^2 = rac{1}{N} (N - (d + 1)) ||noise||^2$$

即

$$\overline{E}_{in} = noiselevel*(1-rac{d+1}{N})$$

同样,对 E_{out} 有如下结论:

$$\overline{E}_{out} = noiselevel*(1 + rac{d+1}{N})$$

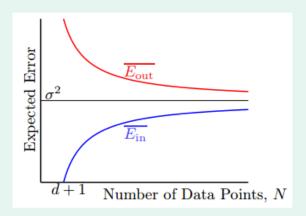
这个证明有点复杂,但是我们可以这样理解: \overline{E}_{in} 与 \overline{E}_{out} 形式上只差了 $\frac{(d+1)}{N}$ 项,从哲

学上来说, \overline{E}_{in} 是我们看得到的样本的平均误差,如果有noise,我们把预测往noise那边偏一点,让 \overline{E}_{in} 好看一点点,所以减去 $\frac{(d+1)}{N}$ 项。那么同时,新的样本 \overline{E}_{out} 是我们看不到的,如果noise在反方向,那么 \overline{E}_{out} 就应该加上 $\frac{(d+1)}{N}$ 项。

我们把 \overline{E}_{in} 与 \overline{E}_{out} 画出来,得到学习曲线:

The Learning Curve

 $\overline{E_{\text{out}}} = \text{noise level} \cdot \left(1 + \frac{d+1}{N}\right)$ $\overline{E_{\text{in}}} = \text{noise level} \cdot \left(1 - \frac{d+1}{N}\right)$



- both converge to σ^2 (**noise** level) for $N \to \infty$
- expected generalization error: $\frac{2(d+1)}{N}$
 - -similar to worst-case guarantee from VC

linear regression (LinReg): learning 'happened'!

当N足够大时, \overline{E}_{in} 与 \overline{E}_{out} 逐渐接近,满足 $\overline{E}_{in} \approx \overline{E}_{out}$,且数值保持在noise level。这就类似VC理论,证明了当N足够大的时候,这种线性最小二乘法是可以进行机器学习的,算法有效!

四、Linear Regression方法解决Linear Classification问题

之前介绍的Linear Classification问题使用的Error Measure方法用的是0/1 error,那么 Linear Regression的squared error是否能够应用到Linear Classification问题?

Linear Classification vs. Linear Regression

Linear Classification

$$\mathcal{Y} = \{-1, +1\}$$

$$h(\mathbf{x}) = \operatorname{sign}(\mathbf{w}^T \mathbf{x})$$

$$\operatorname{err}(\hat{y}, y) = [\hat{y} \neq y]$$

NP-hard to solve in general

Linear Regression

$$\mathcal{Y} = \mathbb{R}$$

$$h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

$$\operatorname{err}(\hat{y}, y) = (\hat{y} - y)^2$$

efficient analytic solution

 $\{-1,+1\} \subset \mathbb{R}$: linear regression for classification?

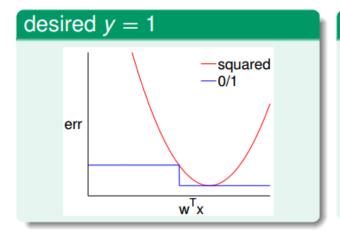
- 1 run LinReg on binary classification data \mathcal{D} (efficient)
- 2 return $g(\mathbf{x}) = \text{sign}(\mathbf{w}_{LIN}^T \mathbf{x})$

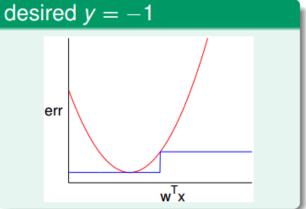
but explanation of this heuristic?

下图展示了两种错误的关系,一般情况下,squared error曲线在0/1 error曲线之上。即 $err_{0/1} \leq err_{sqr}$.

Relation of Two Errors

$$\operatorname{err}_{0/1} = \left[\operatorname{sign}(\mathbf{w}^T \mathbf{x}) \neq y \right] \quad \operatorname{err}_{\operatorname{sqr}} = \left(\mathbf{w}^T \mathbf{x} - y \right)^2$$





 $\text{err}_{0/1} \leq \text{err}_{sqr}$

根据之前的VC理论, E_{out} 的上界满足:

Linear Regression for Binary Classification

 $err_{0/1} \le err_{sqr}$

classification
$$E_{\text{out}}(\mathbf{w}) \overset{\text{VC}}{\leq} \text{ classification } E_{\text{in}}(\mathbf{w}) + \sqrt{\dots}$$

 $\leq \text{ regression } E_{\text{in}}(\mathbf{w}) + \sqrt{\dots}$

- (loose) upper bound err_{sqr} as err to approximate err_{0/1}
- trade bound tightness for efficiency

w_{LIN}: useful baseline classifier, or as initial PLA/pocket vector

从图中可以看出,用 err_{sqr} 代替 $err_{0/1}$, E_{out} 仍然有上界,只不过是上界变得宽松了。也就是说用线性回归方法仍然可以解决线性分类问题,效果不会太差。二元分类问题得到了一个更宽松的上界,但是也是一种更有效率的求解方式。

五、总结

本节课,我们主要介绍了Linear Regression。首先,我们从问题出发,想要找到一条直线拟合实际数据值;然后,我们利用最小二乘法,用解析形式推导了权重w的 closed-form解;接着,用图形的形式得到 $E_{out}-E_{in} \approx \frac{2(N+1)}{N}$,证明了linear regression是可以进行机器学习的,;最后,我们证明linear regressin这种方法可以用在binary classification上,虽然上界变宽松了,但是仍然能得到不错的学习方法。

注明:

文章中所有的图片均来自台湾大学林轩田《机器学习基石》课程