# 林轩田《机器学习基石》课程笔记15 -- Validation

作者: 红色石头 公众号: Al有道 (id: redstonewill)

上节课我们主要讲了为了避免overfitting,可以使用regularization方法来解决。在之前的 $E_{in}$ 上加上一个regularizer,生成 $E_{aug}$ ,将其最小化,这样可以有效减少模型的复杂度,避免过拟合现象的发生。那么,机器学习领域还有许多选择,如何保证训练的模型具有良好的泛化能力?本节课将介绍一些概念和方法来解决这个选择性的问题。

### — Model Selection Problem

机器学习模型建立的过程中有许多选择,例如对于简单的二元分类问题,首先是算法A的选择,有PLA,pocket,linear regression,logistic regression等等;其次是迭代次数T的选择,有100,1000,10000等等;之后是学习速率 $\eta$ 的选择,有1,0.01,0.0001等等;接着是模型特征转换 $\Phi$ 的选择,有linear,quadratic,poly-10,Legendre-poly-10等等;然后是正则化regularizer的选择,有L2,L1等等;最后是正则化系数 $\lambda$ 的选择,有0,0.01,1等等。不同的选择搭配,有不同的机器学习效果。我们的目标就是找到最合适的选择搭配,得到一个好的矩g,构建最佳的机器学习模型。

```
Even Just for Binary Classification . . . \mathcal{A} \in \{ \text{ PLA, pocket, linear regression, logistic regression} \} \\ \times \\ T \in \{ 100, 1000, 10000 \} \\ \times \\ \eta \in \{ 1, 0.01, 0.0001 \} \\ \times \\ \Phi \in \{ \text{ linear, quadratic, poly-10, Legendre-poly-10} \} \\ \times \\ \Omega(\mathbf{w}) \in \{ \text{ L2 regularizer, L1 regularizer, symmetry regularizer} \} \\ \times \\ \lambda \in \{ 0, 0.01, 1 \}
```

假设有M个模型,对应有 $H_1,H_2,\cdots,H_M$ ,即有M个hypothesis set,演算法为 $A_1,A_2,\cdots,A_M$ ,共M个。我们的目标是从这M个hypothesis set中选择一个模型 $H_{m^*}$ ,通过演算法 $A_{m^*}$ 对样本集D的训练,得到一个最好的矩 $g_{m^*}$ ,使其 $E_{out}(g_{m^*})$ 最小。所以,问题的关键就是机器学习中如何选择到最好的矩 $g_{m^*}$ 。

考虑有这样一种方法,对M个模型分别计算使 $E_{in}$ 最小的矩g,再横向比较,取其中能使 $E_{in}$ 最小的模型的矩 $g_{m^*}$ :

$$m^* = \underset{1 \le m \le M}{\operatorname{argmin}}(E_m = \underset{\mathsf{Ein}}{E_{\mathsf{in}}}(\mathcal{A}_m(\mathcal{D})))$$

但是 $E_{in}$ 足够小并不能表示模型好,反而可能表示训练的矩 $g_{m^*}$ 发生了过拟合,泛化能力很差。而且这种"模型选择+学习训练"的过程,它的VC Dimension是 $d_{VC}(H_1 \cup H_2)$ ,模型复杂度增加。总的来说,泛化能力差,用 $E_{in}$ 来选择模型是不好的。

另外一种方法,如果有这样一个独立于训练样本的测试集,将M个模型在测试集上进行测试,看一下 $E_{test}$ 的大小,则选取 $E_{test}$ 最小的模型作为最佳模型:

$$m^* = \underset{1 \le m \le M}{\operatorname{argmin}} (E_m = \underset{test}{E_{test}} (\mathcal{A}_m(\mathcal{D})))$$

这种测试集验证的方法,根据finite-bin Hoffding不等式,可以得到:

$$E_{out}(g_{m^*}) \leq E_{test}(g_{m^*}) + O(\sqrt{rac{logM}{N_{test}}})$$

由上式可以看出,模型个数M越少,测试集数目越大,那么 $O(\sqrt{rac{log M}{N_{test}}})$ 越小,即 $E_{test}(g_{m^*})$ 越接近于 $E_{out}(g_{m^*})$ 。

下面比较一下之前讲的两种方法,第一种方法使用 $E_{in}$ 作为判断基准,使用的数据集就是训练集D本身;第二种方法使用 $E_{test}$ 作为判断基准,使用的是独立于训练集D之外的测试集。前者不仅使用D来训练不同的 $g_m$ ,而且又使用D来选择最好的 $g_{m^*}$ ,那么 $g_{m^*}$ 对未知数据并不一定泛化能力好。举个例子,这相当于老师用学生做过的练习题再来对学生进行考试,那么即使学生得到高分,也不能说明他的学习能力强。所以最小化 $E_{in}$ 的方法并不科学。而后者使用的是独立于D的测试集,相当于新的考试题能更好地反映学生的真实水平,所以最小化 $E_{test}$ 更加理想。

### in-sample error En

- calculated from D
- feasible on hand
- 'contaminated' as D also used by A<sub>m</sub> to 'select' g<sub>m</sub>

### test error Etest

- calculated from D<sub>test</sub>
- infeasible in boss's safe
- 'clean' as D<sub>test</sub> never used for selection before

但是,我们拿到的一都是训练集D,测试集是拿不到的。所以,寻找一种折中的办法,我们可以使用已有的训练集D来创造一个验证集validation set,即从D中划出一部分 $D_{val}$ 作为验证集。D另外的部分作为训练模型使用, $D_{val}$ 独立开来,用来测试各个模型的好坏,最小化 $E_{val}$ ,从而选择最佳的 $g_{m^*}$ 。

### something in between: E<sub>val</sub>

- calculated from  $\mathcal{D}_{\text{val}} \subset \mathcal{D}$
- feasible on hand
- 'clean' if  $\mathcal{D}_{\text{val}}$  never used by  $\mathcal{A}_m$  before

### 二、Validation

从训练集D中抽出一部分K个数据作为验证集 $D_{val}$ , $D_{val}$ 对应的error记为 $E_{val}$ 。这样做的一个前提是保证 $D_{val}$ 独立同分布(iid)于P(x,y),也就是说 $D_{val}$ 的选择是从D中平均随机抽样得到的,这样能够把 $E_{val}$ 与 $E_{out}$ 联系起来。D中去除 $D_{val}$ 后的数据就是供模型选择的训练数据 $D_{train}$ ,其大小为N-k。从 $D_{train}$ 中选择最好的矩,记为 $g_m^-$ 。

假如D共有1000个样本,那么可以选择其中900个 $D_{train}$ ,剩下的100个作为 $D_{val}$ 。 使用 $D_{train}$ 训练模型,得到最佳的 $g_m^-$ ,使用 $g_m^-$ 对 $D_{val}$ 进行验证,得到如下Hoffding不等式:

$$E_{out}(g_m^-) \leq E_{val}(g_m^-) + O(\sqrt{rac{log M}{K}})$$

假设有M种模型hypothesis set, $D_{val}$ 的数量为K,那么从每种模型m中得到一个在 $D_{val}$ 上表现最好的矩,再横向比较,从M个矩中选择一个最好的m\*作为我们最终得到的模型。

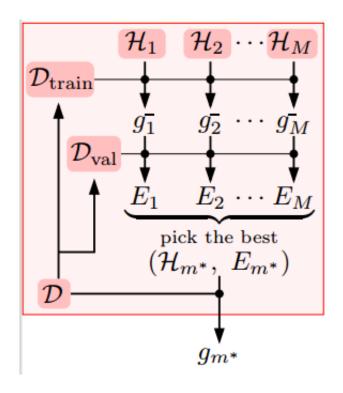
$$m^* = \underset{1 \le m \le M}{\operatorname{argmin}} (E_m = \underset{\mathsf{Eval}}{E_{\mathsf{val}}} (\mathcal{A}_m(\mathcal{D}_{\mathsf{train}})))$$

现在由于数量为N的总样本D的一部分K作为验证集,那么只有N-k个样本可供训练。 从 $D_{train}$ 中得到最好的 $g_{m^*}^-$ ,而总样本D对应的最好的矩为 $g_{m^*}$ 。根据之前的leraning curve很容易知道,训练样本越多,得到的模型越准确,其hypothesis越接近target function,即D的 $E_{out}$ 比 $D_{train}$ 的 $E_{out}$ 要小:

$$E_{ ext{out}}\left(\underbrace{oldsymbol{g_{m^*}}}_{\mathcal{A}_{m^*}(\mathcal{D})}
ight) \leq E_{ ext{out}}\left(\underbrace{oldsymbol{g_{m^*}}}_{\mathcal{A}_{m^*}(\mathcal{D}_{ ext{train}})}
ight)$$

所以,我们通常的做法是通过 $D_{val}$ 来选择最好的矩 $g_{m^*}^-$ 对应的模型 $m^*$ ,再对整体样本集D使用该模型进行训练,最终得到最好的矩 $g_{m^*}$ 。

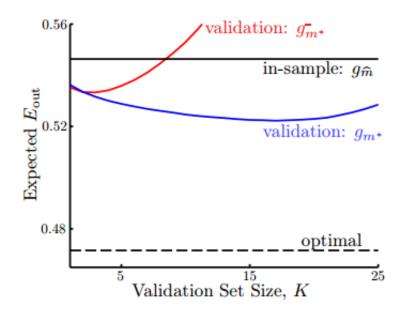
总结一下,使用验证集进行模型选择的整个过程为:先将D分成两个部分,一个是训练样本 $D_{train}$ ,一个是验证集 $D_{val}$ 。若有M个模型,那么分别对每个模型在 $D_{train}$ 上进行训练,得到矩 $g_m$ ,再用 $D_{val}$ 对每个 $g_m$ 进行验证,选择表现最好的矩 $g_{m^*}$ ,则该矩对应的模型被选择。最后使用该模型对整个D进行训练,得到最终的 $g_{m^*}$ 。下图展示了整个模型选择的过程:



#### 不等式关系满足:

$$E_{out}(g_{m^*}) \leq E_{out}(g_{m^*}^-) \leq E_{val}(g_{m^*}^-) + O(\sqrt{rac{logM}{K}})$$

下面我们举个例子来解释这种模型选择的方法的优越性,假设有两个模型:一个是5阶多项式 $H_{\Phi_5}$ ,一个是10阶多项式 $H_{\Phi_{10}}$ 。通过不使用验证集和使用验证集两种方法对模型选择结果进行比较,分析结果如下:



图中,横坐标表示验证集数量K,纵坐标表示 $E_{out}$ 大小。黑色水平线表示没有验证集,完全使用 $E_{in}$ 进行判断基准,那么 $H_{\Phi_{10}}$ 更好一些,但是这种方法的 $E_{out}$ 比较大,而且与K无关。黑色虚线表示测试集非常接近实际数据,这是一种理想的情况,其

 $E_{out}$ 很小,同样也与K无关,实际中很难得到这条虚线。红色曲线表示使用验证集,但是最终选取的矩是 $g_{m^*}^-$ ,其趋势是随着K的增加,它对应的 $E_{out}$ 先减小再增大,当K大于一定值的时候,甚至会超过黑色水平线。蓝色曲线表示也使用验证集,最终选取的矩是 $g_{m^*}$ ,其趋势是随着K的增加,它对应的 $E_{out}$ 先缓慢减小再缓慢增大,且一直位于红色曲线和黑色直线之下。从此可见,蓝色曲线对应的方法最好,符合我们之前讨论的使用验证集进行模型选择效果最好。

这里提一点,当K大于一定的值时,红色曲线会超过黑色直线。这是因为随着K的增大, $D_{val}$ 增大,但可供模型训练的 $D_{train}$ 在减小,那得到的 $g_{m^*}^-$ 不具有很好的泛化能力,即对应的 $E_{out}$ 会增大,甚至当K增大到一定值时,比 $E_{in}$ 模型更差。

那么,如何设置验证集K值的大小呢?根据之前的分析:

当K值很大时, $E_{val} \approx E_{out}$ ,但是 $g_m^-$ 与 $g_m$ 相差很大;当K值很小是, $g_m^- \approx g_m$ ,但是 $E_{val}$ 与 $E_{out}$ 可能相差很大。所以有个折中的办法,通常设置 $k=\frac{N}{5}$ 。值得一提的是,划分验证集,通常并不会增加整体时间复杂度,反而会减少,因为 $D_{train}$ 减少了。

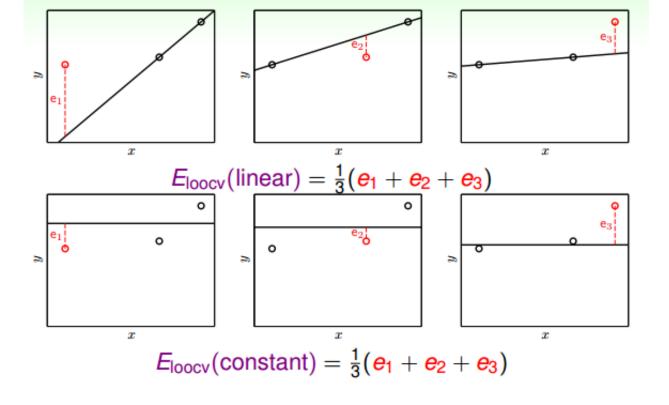
### 三、Leave-One-Out Cross Validation

假如考虑一个极端的例子,k=1,也就是说验证集大小为1,即每次只用一组数据对 $g_m$ 进行验证。这样做的优点是 $g_m^- \approx g_m$ ,但是 $E_{val}$ 与 $E_{out}$ 可能相差很大。为了避免 $E_{val}$ 与 $E_{out}$ 相差很大,每次从D中取一组作为验证集,直到所有样本都作过验证集,共计算N次,最后对验证误差求平均,得到 $E_{loocv}(H,A)$ ,这种方法称之为留一法交叉验证,表达式为:

$$E_{loocv}(H,A) = rac{1}{N} \sum_{n=1}^{N} e_n = rac{1}{N} \sum_{n=1}^{N} err(g_n^-(x_n), y_n)$$

这样求平均的目的是为了让 $E_{loocv}(H,A)$ 尽可能地接近 $E_{out}(g)$ 。

下面用一个例子图解留一法的过程:



如上图所示,要对二维平面上的三个点做拟合,上面三个图表示的是线性模型,下面三个图表示的是常数模型。对于两种模型,分别使用留一交叉验证法来计算 $E_{loocv}$ ,计算过程都是每次将一个点作为验证集,其他两个点作为训练集,最终将得到的验证误差求平均值,就得到了 $E_{loocv}(linear)$ 和 $E_{loocv}(constant)$ ,比较两个值的大小,取值小对应的模型即为最佳模型。

$$m^* = \underset{1 \le m \le M}{\operatorname{argmin}} (E_m = E_{\text{loocv}}(\mathcal{H}_m, \mathcal{A}_m))$$

接下来,我们从理论上分析Leave-One-Out方法的可行性,即 $E_{loocv}(H,A)$ 是否能保证 $E_{out}$ 的矩足够好?假设有不同的数据集D,它的期望分布记为 $\varepsilon_D$ ,则其 $E_{loocv}(H,A)$ 可以通过推导,等于 $E_{out}(N-1)$ 的平均值。由于N-1近似为N, $E_{out}(N-1)$ 的平均值也近似等于 $E_{out}(N)$ 的平均值。具体推导过程如下:

$$\mathcal{E}_{\mathcal{D}} E_{loocv}(\mathcal{H}, \mathcal{A}) = \mathcal{E}_{\mathcal{D}} \frac{1}{N} \sum_{n=1}^{N} e_{n} = \frac{1}{N} \sum_{n=1}^{N} \mathcal{E}_{\mathcal{D}} e_{n}$$

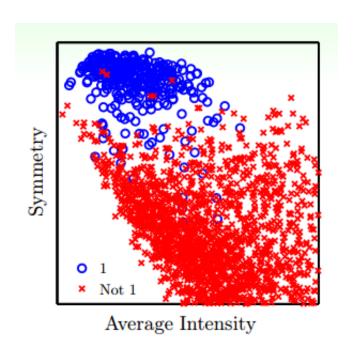
$$= \frac{1}{N} \sum_{n=1}^{N} \mathcal{E}_{\mathcal{D}_{n}(\mathbf{x}_{n}, \mathbf{y}_{n})} \operatorname{err}(g_{n}^{-}(\mathbf{x}_{n}), \mathbf{y}_{n})$$

$$= \frac{1}{N} \sum_{n=1}^{N} \mathcal{E}_{\mathcal{D}_{n}} E_{out}(g_{n}^{-})$$

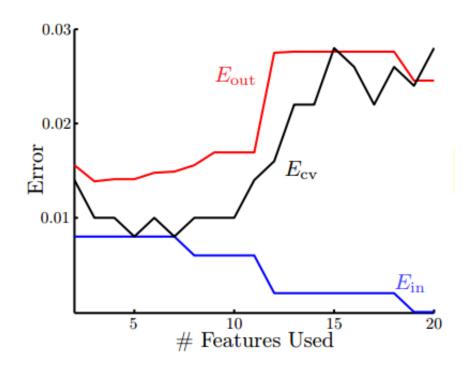
$$= \frac{1}{N} \sum_{n=1}^{N} \overline{E_{out}}(N-1) = \overline{E_{out}}(N-1)$$

最终我们得到的结论是 $E_{loocv}(H,A)$ 的期望值和 $E_{out}(g^-)$ 的期望值是相近的,这代表得到了比较理想的 $E_{out}(g)$ ,Leave-One-Out方法是可行的。

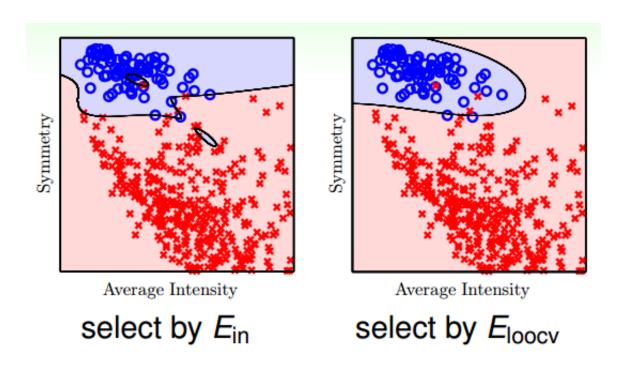
举一个例子,使用两个特征: Average Intensity和Symmetry加上这两个特征的非线性变换(例如高阶项)来进行手写数字识别。平面特征分布如下图所示:



Error与特征数量的关系如下图所示:



从图中我们看出,随着特征数量的增加, $E_{in}$ 不断减小, $E_{out}$ 先减小再增大,虽然  $E_{in}$ 是不断减小的,但是它与 $E_{out}$ 的差距越来越大,发生了过拟合,泛化能力太差。 而 $E_{cv}$ 与 $E_{out}$ 的分布基本一致,能较好地反映 $E_{out}$ 的变化。所以,我们只要使用 Leave-One-Out方法得到使 $E_{cv}$ 最小的模型,就能保证其 $E_{out}$ 足够小。下图是分别使 用 $E_{in}$ 和 $E_{out}$ 进行训练得到的分类曲线:



很明显可以看出,使用 $E_{in}$ 发生了过拟合,而 $E_{loocv}$ 分类效果更好,泛化能力强。

## 四、V-Fold Cross Validation

接下来我们看看Leave-One-Out可能的问题是什么。首先,第一个问题是计算量,假设N=1000,那么就需要计算1000次的 $E_{loocv}$ ,再计算其平均值。当N很大的时候,计算量是巨大的,很耗费时间。第二个问题是稳定性,例如对于二分类问题,取值只有0和1两种,预测本身存在不稳定的因素,那么对所有的 $E_{loocv}$ 计算平均值可能会带来很大的数值跳动,稳定性不好。所以,这两个因素决定了Leave-One-Out方法在实际中并不常用。

针对Leave-One-Out的缺点,我们对其作出了改进。Leave-One-Out是将N个数据分成N分,那么改进措施是将N个数据分成V份(例如V=10),计算过程与Leave-One-Out相似。这样可以减少总的计算量,又能进行交叉验证,得到最好的矩,这种方法称为V-折交叉验证。其实Leave-One-Out就是V-折交叉验证的一个极端例子。

$$E_{cv}(H,A) = rac{1}{V} \sum_{v=1}^{V} E_{val}^{(V)}(g_V^-)$$

所以呢,一般的Validation使用V-折交叉验证来选择最佳的模型。值得一提的是 Validation的数据来源也是样本集中的,所以并不能保证交叉验证的效果好,它的模型 一定好。只有样本数据越多,越广泛,那么Validation的结果越可信,其选择的模型泛 化能力越强。

### 五、总结

本节课主要介绍了Validation验证。先从如何选择一个好的模型开始切入,例如使用  $E_{in}$ 、 $E_{test}$ 都是不太好的,最终使用 $E_{val}$ 来进行模型选择。然后详细介绍了 Validation的过程。最后,介绍了Leave-One-Out和V-Fold Cross两种验证方法,比较它们各自的优点和缺点,实际情况下,V-Fold Cross更加常用。

#### 注明:

文章中所有的图片均来自台湾大学林轩田《机器学习基石》课程