# 林轩田《机器学习技法》课程笔记2 -- Dual Support Vector Machine

作者: 红色石头 公众号: Al有道 (id: redstonewill)

上节课我们主要介绍了线性支持向量机(Linear Support Vector Machine)。Linear SVM的目标是找出最"胖"的分割线进行正负类的分离,方法是使用二次规划来求出分类线。本节课将从另一个方面入手,研究对偶支持向量机(Dual Support Vector Machine),尝试从新的角度计算得出分类线,推广SVM的应用范围。

#### **Motivation of Dual SVM**

首先,我们回顾一下,对于非线性SVM,我们通常可以使用非线性变换将变量从x域转换到z域中。然后,在z域中,根据上一节课的内容,使用线性SVM解决问题即可。上一节课我们说过,使用SVM得到large-margin,减少了有效的VC Dimension,限制了模型复杂度;另一方面,使用特征转换,目的是让模型更复杂,减小 $E_{in}$ 。所以说,非线性SVM是把这两者目的结合起来,平衡这两者的关系。那么,特征转换下,求解QP问题在z域中的维度设为 $\hat{d}+1$ ,如果模型越复杂,则 $\hat{d}+1$ 越大,相应求解这个QP问题也变得很困难。当 $\hat{d}$ 无限大的时候,问题将会变得难以求解,那么有没有什么办法可以解决这个问题呢?一种方法就是使SVM的求解过程不依赖 $\hat{d}$ ,这就是我们本节课所要讨论的主要内容。

Mon-Linear Hard-Margin SVM

$$\begin{array}{ll}
\min_{b,\mathbf{w}} & \frac{1}{2}\mathbf{w}^T\mathbf{w} \\
\text{s. t.} & y_n(\mathbf{w}^T \underbrace{\mathbf{z}_n} + b) \geq 1, \\
\text{for } n = 1, 2, \dots, N
\end{array}$$

$$\begin{array}{ll}
\mathbf{v} = \begin{bmatrix} \mathbf{0} & \mathbf{0}_{\tilde{d}}^T \\ \mathbf{0}_{\tilde{d}} & \mathbf{I}_{\tilde{d}} \end{bmatrix}; \mathbf{p} = \mathbf{0}_{\tilde{d}+1}; \\
\mathbf{a}_n^T = y_n \begin{bmatrix} 1 & \mathbf{z}_n^T \end{bmatrix}; c_n = 1$$

$$\begin{bmatrix} \mathbf{b} \\ \mathbf{w} \end{bmatrix} \leftarrow \mathsf{QP}(\mathsf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

$$\mathbf{return } \mathbf{b} \in \mathbb{R} \& \mathbf{w} \in \mathbb{R}^{\tilde{d}} \text{ with } \\
g_{\mathsf{SVM}}(\mathbf{x}) = \mathsf{sign}(\mathbf{w}^T \mathbf{\Phi}(\mathbf{x}) + b)$$

比较一下,我们上一节课所讲的Original SVM二次规划问题的变量个数是 $\hat{d} + 1$ ,有N

个限制条件;而本节课,我们把问题转化为对偶问题('Equivalent' SVM),同样是二次规划,只不过变量个数变成N个,有N+1个限制条件。这种对偶SVM的好处就是问题只跟N有关,与 $\hat{d}$ 无关,这样就不存在上文提到的当 $\hat{d}$ 无限大时难以求解的情况。

#### Original SVM

(convex) QP of

- $\tilde{d} + 1$  variables
- N constraints

#### **Equivalent' SVM**

(convex) QP of

- N variables
- N + 1 constraints

如何把问题转化为对偶问题('Equivalent' SVM) ,其中的数学推导非常复杂,本文不做详细数学论证,但是会从概念和原理上进行简单的推导。

还记得我们在《机器学习基石》课程中介绍的Regularization中,在最小化 $E_{in}$ 的过程中,也添加了限制条件: $w^Tw \leq C$ 。我们的求解方法是引入拉格朗日因子 $\lambda$ ,将有条件的最小化问题转换为无条件的最小化问题:

 $min~E_{aug}(w)=E_{in}(w)+rac{\lambda}{N}w^Tw$ ,最终得到的w的最优化解为:

$$abla E_{in}(w) + rac{2\lambda}{N}w = 0$$

所以,在regularization问题中, $\lambda$ 是已知常量,求解过程变得容易。那么,对于dual SVM问题,同样可以引入 $\lambda$ ,将条件问题转换为非条件问题,只不过 $\lambda$ 是未知参数,且个数是N,需要对其进行求解。

# Regularization by Constrained-Minimizing $E_{in}$

 $\min_{\mathbf{w}} E_{in}(\mathbf{w}) \text{ s.t. } \mathbf{w}^T \mathbf{w} \leq C$ 



# Regularization by Minimizing $E_{aug}$

$$\min_{\mathbf{w}} E_{\text{aug}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}) + \frac{\lambda}{N} \mathbf{w}^{T} \mathbf{w}$$

• C equivalent to some  $\lambda \geq 0$  by checking optimality condition

$$\nabla E_{\rm in}(\mathbf{w}) + \frac{2\lambda}{N}\mathbf{w} = \mathbf{0}$$

- regularization: view λ as given parameter instead of C, and solve 'easily'
- dual SVM: view  $\lambda$ 's as unknown given the constraints, and solve them as variables instead

如何将条件问题转换为非条件问题?上一节课我们介绍的SVM中,目标是: $min\ \frac{1}{2}w^Tw$ ,条件是: $y_n(w^Tz_n+b)\geq 1,\ for\ n=1,2,\cdots,N$ 。首先,我们令拉格朗日因子为 $\alpha_n$ (区别于regularization),构造一个函数:

$$L(b,w,lpha)=rac{1}{2}w^Tw+\sum_{n=1}^Nlpha_n(1-y_n(w^Tz_n+b))$$

这个函数右边第一项是SVM的目标,第二项是SVM的条件和拉格朗日因子 $lpha_n$ 的乘积。我们把这个函数称为拉格朗日函数,其中包含三个参数:b,w, $lpha_n$ 。

Lagrange Function
with Lagrange multipliers 
$$\alpha_n$$
,

with Lagrange multipliers  $\alpha_n$ ,

s.t.  $y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1$ ,
for  $n = 1, 2, ..., N$ 

$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1$$
,
$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1$$

下面,我们利用拉格朗日函数,把SVM构造成一个非条件问题:

$$\begin{aligned} & \text{SVM} \equiv \min_{b,\mathbf{w}} \left( \max_{\substack{\text{all } \alpha_n \geq 0}} \mathcal{L}(b,\mathbf{w},\alpha) \right) = \min_{\substack{b,\mathbf{w}}} \left( \infty \text{ if violate }; \frac{1}{2}\mathbf{w}^T\mathbf{w} \text{ if feasible} \right) \\ & \bullet \text{ any 'violating' } (b,\mathbf{w}) : \max_{\substack{\text{all } \alpha_n \geq 0}} \left( \Box + \sum_{n} \alpha_n (\text{some positive}) \right) \rightarrow \infty \\ & \bullet \text{ any 'feasible' } (b,\mathbf{w}) : \max_{\substack{\text{all } \alpha_n \geq 0}} \left( \Box + \sum_{n} \alpha_n (\text{all non-positive}) \right) = \Box \end{aligned}$$

该最小化问题中包含了最大化问题,怎么解释呢?首先我们规定拉格朗日因子  $\alpha_n \geq 0$ ,根据SVM的限定条件可得: $(1-y_n(w^Tz_n+b))\leq 0$ ,如果没有达到最优解,即有不满足 $(1-y_n(w^Tz_n+b))\leq 0$ 的情况,因为 $\alpha_n\geq 0$ ,那么必然有  $\sum_n \alpha_n(1-y_n(w^Tz_n+b))\geq 0$ 。对于这种大于零的情况,其最大值是无解的。如果对于所有的点,均满足 $(1-y_n(w^Tz_n+b))\leq 0$ ,那么必然有  $\sum_n \alpha_n(1-y_n(w^Tz_n+b))\leq 0$ ,则当 $\sum_n \alpha_n(1-y_n(w^Tz_n+b))=0$ 时,其有最大值,最大值就是我们SVM的目标: $\frac{1}{2}w^Tw$ 。因此,这种转化为非条件的SVM构造函数的形式是可行的。

#### **Lagrange Dual SVM**

现在,我们已经将SVM问题转化为与拉格朗日因子 $\alpha_n$ 有关的最大最小值形式。已知 $\alpha_n \geq 0$ ,那么对于任何固定的 $\alpha'$ ,且 $\alpha'_n \geq 0$ ,一定有如下不等式成立:

for any fixed 
$$\alpha'$$
 with all  $\alpha'_n \geq 0$ , 
$$\min_{b,\mathbf{w}} \left( \max_{\substack{\text{all } \alpha_n \geq 0}} \mathcal{L}(b,\mathbf{w},\alpha) \right) \geq \min_{b,\mathbf{w}} \mathcal{L}(b,\mathbf{w},\alpha')$$

对上述不等式右边取最大值,不等式同样成立:

for best 
$$\alpha' \geq \mathbf{0}$$
 on RHS, 
$$\min_{b,\mathbf{w}} \left( \max_{\substack{\text{all } \alpha_n \geq 0}} \mathcal{L}(b,\mathbf{w},\alpha) \right) \geq \max_{\substack{\text{all } \alpha_n' \geq 0 \\ b,\mathbf{w}}} \min_{\substack{b,\mathbf{w}}} \mathcal{L}(b,\mathbf{w},\alpha')$$
Lagrange dual problem

上述不等式表明,我们对SVM的min和max做了对调,满足这样的关系,这叫做 Lagrange dual problem。不等式右边是SVM问题的下界,我们接下来的目的就是求出 这个下界。

已知>是一种弱对偶关系,在二次规划QP问题中,如果满足以下三个条件:

- 函数是凸的 (convex primal)
- 函数有解 (feasible primal)
- 条件是线性的 (linear constraints)

那么,上述不等式关系就变成强对偶关系, $\geq$ 变成=,即一定存在满足条件的解(b,w,lpha),使等式左边和右边都成立,SVM的解就转化为右边的形式。

经过推导, SVM对偶问题的解已经转化为无条件形式:

$$\max_{\text{all }\boldsymbol{\alpha}_n \geq 0} \left( \min_{\boldsymbol{b}, \mathbf{w}} \underbrace{\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \boldsymbol{\alpha}_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n + \boldsymbol{b}))}_{\mathcal{L}(\boldsymbol{b}, \mathbf{w}, \boldsymbol{\alpha})} \right)$$

其中,上式括号里面的是对拉格朗日函数L(b,w,lpha)计算最小值。那么根据梯度下降算法思想:最小值位置满足梯度为零。首先,令L(b,w,lpha)对参数b的梯度为零:

$$rac{\partial L(b,w,lpha)}{\partial b}=0=-\sum_{n=1}^N lpha_n y_n$$

也就是说,最优解一定满足 $\sum_{n=1}^N \alpha_n y_n = 0$ 。那么,我们把这个条件代入计算max条件中(与 $\alpha_n \geq 0$ 同为条件),并进行化简:

$$\max_{\text{all } \boldsymbol{\alpha}_n \geq 0, \sum y_n \boldsymbol{\alpha}_n = 0} \left( \min_{b, \mathbf{w}} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \boldsymbol{\alpha}_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n)) \right)$$

这样,SVM表达式消去了b,问题化简了一些。然后,再根据最小值思想,令L(b,w,lpha)对参数w的梯度为零:

$$rac{\partial L(b,w,lpha}{\partial w}=0=w-\sum_{n=1}^Nlpha_ny_nz_n$$

即得到:

$$w = \sum_{n=1}^N lpha_n y_n z_n$$

也就是说,最优解一定满足 $w=\sum_{n=1}^N lpha_n y_n z_n$ 。那么,同样我们把这个条件代入并进行化简:

$$\max_{\substack{\text{all } \boldsymbol{\alpha}_n \geq 0, \sum y_n \boldsymbol{\alpha}_n = 0, \mathbf{w} = \sum \boldsymbol{\alpha}_n y_n \mathbf{z}_n \\ \text{all } \boldsymbol{\alpha}_n \geq 0, \sum y_n \boldsymbol{\alpha}_n = 0, \mathbf{w} = \sum \boldsymbol{\alpha}_n y_n \mathbf{z}_n}} \left( \min_{\substack{b, \mathbf{w}}} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \boldsymbol{\alpha}_n - \mathbf{w}^T \mathbf{w} \right)$$

$$\iff \max_{\substack{\text{all } \boldsymbol{\alpha}_n \geq 0, \sum y_n \boldsymbol{\alpha}_n = 0, \mathbf{w} = \sum \boldsymbol{\alpha}_n y_n \mathbf{z}_n}} -\frac{1}{2} \| \sum_{n=1}^N \boldsymbol{\alpha}_n y_n \mathbf{z}_n \|^2 + \sum_{n=1}^N \boldsymbol{\alpha}_n$$

这样,SVM表达式消去了w,问题更加简化了。这时候的条件有3个:

- all  $lpha_n \geq 0$
- $\sum_{n=1}^N \alpha_n y_n = 0$
- $w = \sum_{n=1}^N lpha_n y_n z_n$

SVM简化为只有 $lpha_n$ 的最佳化问题,即计算满足上述三个条件下,函数 $-rac{1}{2}||\sum_{n=1}^Nlpha_ny_nz_n||^2+\sum_{n=1}^Nlpha_n$ 最小值时对应的 $lpha_n$ 是多少。

总结一下,SVM最佳化形式转化为只与 $\alpha_n$ 有关:

$$\max_{\text{all } \boldsymbol{\alpha}_n \geq 0, \sum y_n \boldsymbol{\alpha}_n = 0, \mathbf{w} = \sum \boldsymbol{\alpha}_n y_n \mathbf{z}_n} - \frac{1}{2} \| \sum_{n=1}^N \boldsymbol{\alpha}_n y_n \mathbf{z}_n \|^2 + \sum_{n=1}^N \boldsymbol{\alpha}_n$$

其中,满足最佳化的条件称之为Karush-Kuhn-Tucker(KKT):

if primal-dual optimal  $(b, \mathbf{w}, \alpha)$ ,

- primal feasible: y<sub>n</sub>(w<sup>T</sup>z<sub>n</sub> + b) ≥ 1
- dual feasible:  $\alpha_n \geq 0$
- dual-inner optimal:  $\sum y_n \alpha_n = 0$ ;  $\mathbf{w} = \sum \alpha_n y_n \mathbf{z}_n$
- primal-inner optimal (at optimal all 'Lagrange terms' disappear):

$$\alpha_n(1-y_n(\mathbf{w}^T\mathbf{z}_n+b))=0$$

—called Karush-Kuhn-Tucker (KKT) conditions, necessary for optimality [& sufficient here]

在下一部分中,我们将利用KKT条件来计算最优化问题中的lpha,进而得到b和w。

#### **Solving Dual SVM**

上面我们已经得到了dual SVM的简化版了,接下来,我们继续对它进行一些优化。首先,将max问题转化为min问题,再做一些条件整理和推导,得到:

#### standard hard-margin SVM dual

$$\begin{aligned} & \min_{\pmb{\alpha}} & & \frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{N} \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^{N} \alpha_n \\ & \text{subject to} & & \sum_{n=1}^{N} y_n \alpha_n = 0; \\ & & & \alpha_n \geq 0, \text{for } n = 1, 2, \dots, N \end{aligned}$$

(convex) QP of N variables & N+1 constraints, as promised

显然,这是一个convex的QP问题,且有N个变量 $\alpha_n$ ,限制条件有N+1个。则根据上一节课讲的QP解法,找到Q,p,A,c对应的值,用软件工具包进行求解即可。

optimal 
$$\alpha=$$
?

min  $\frac{1}{2}\sum\limits_{n=1}^{N}\sum\limits_{m=1}^{N}\alpha_{n}\alpha_{m}y_{n}y_{m}\mathbf{z}_{n}^{T}\mathbf{z}_{m}$ 
 $-\sum\limits_{n=1}^{N}\alpha_{n}$ 
subject to  $\sum\limits_{n=1}^{N}y_{n}\alpha_{n}=0;$ 
 $\alpha_{n}\geq0,$ 
for  $n=1,2,\ldots,N$ 
 $\mathbf{z}$ 
 $\mathbf$ 

求解过程很清晰,但是值得注意的是, $q_{n,m}=y_ny_mz_n^Tz_m$ ,大部分值是非零的,称为dense。当N很大的时候,例如N=30000,那么对应的 $Q_D$ 的计算量将会很大,存储空间也很大。所以一般情况下,对dual SVM问题的矩阵 $Q_D$ ,需要使用一些特殊的方法,这部分内容就不再赘述了。

- $q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m$ , often non-zero
- if N = 30,000, dense Q<sub>D</sub> (N by N symmetric) takes > 3G RAM
- need special solver for
  - not storing whole Q<sub>D</sub>
  - · utilizing special constraints properly

to scale up to large N

得到 $lpha_n$ 之后,再根据之前的KKT条件,就可以计算出w和b了。首先利用条件 $w=\sum lpha_n y_n z_n$ 得到w,然后利用条件 $lpha_n (1-y_n(w^Tz_n+b))=0$ ,取任一 $lpha_n 
eq 0$ 即 $lpha_n$ >0的点,得到 $1-y_n(w^Tz_n+b)=0$ ,进而求得 $b=y_n-w^Tz_n$ 。

#### KKT conditions

if primal-dual optimal  $(b, \mathbf{w}, \alpha)$ ,

- primal feasible:  $y_n(\mathbf{w}^T\mathbf{z}_n + b) \geq 1$
- dual feasible:  $\alpha_n \ge 0$
- dual-inner optimal:  $\sum y_n \alpha_n = 0$ ;  $\mathbf{w} = \sum \alpha_n y_n \mathbf{z}_n$
- primal-inner optimal (at optimal all 'Lagrange terms' disappear):

$$\alpha_n(1 - y_n(\mathbf{w}^T\mathbf{z}_n + \mathbf{b})) = 0$$
 (complementary slackness)

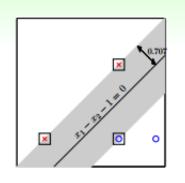
- optimal  $\alpha \Longrightarrow$  optimal w? easy above!
- optimal  $\alpha \Longrightarrow$  optimal b? a range from primal feasible & equality from comp. slackness if one  $\alpha_n > 0 \Rightarrow b = y_n \mathbf{w}^T \mathbf{z}_n$

值得注意的是,计算b值, $\alpha_n$ >0时,有 $y_n(w^Tz_n+b)=1$ 成立。  $y_n(w^Tz_n+b)=1$ 正好表示的是该点在SVM分类线上,即fat boundary。也就是说,满足 $\alpha_n$ >0的点一定落在fat boundary上,这些点就是Support Vector。这是一个非常有趣的特性。

## Messages behind Dual SVM

回忆一下,上一节课中,我们把位于分类线边界上的点称为support vector(candidates)。本节课前面介绍了 $lpha_n$ >0的点一定落在分类线边界上,这些点称之为support vector(注意没有candidates)。也就是说分类线上的点不一定都是支

- on boundary: 'locates' fattest hyperplane; others: not needed
- examples with  $\alpha_n > 0$ : on boundary
- call α<sub>n</sub> > 0 examples (z<sub>n</sub>, y<sub>n</sub>)
   support vectors (candidates)
- SV (positive α<sub>n</sub>)
   ⊆ SV candidates (on boundary)



SV只由 $\alpha_n$ >0的点决定,根据上一部分推导的w和b的计算公式,我们发现,w和b仅由 SV即 $\alpha_n$ >0的点决定,简化了计算量。这跟我们上一节课介绍的分类线只由"胖"边界上的点所决定是一个道理。也就是说,样本点可以分成两类:一类是support vectors,通过support vectors可以求得fattest hyperplane;另一类不是support vectors,对我们求得fattest hyperplane没有影响。

- only SV needed to compute **w**:  $\mathbf{w} = \sum_{n=1}^{N} \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$
- only SV needed to compute b:  $b = y_n \mathbf{w}^T \mathbf{z}_n$  with any SV  $(\mathbf{z}_n, y_n)$

回过头来,我们来比较一下SVM和PLA的w公式:

SVM
$$\mathbf{w}_{\text{SVM}} = \sum_{n=1}^{N} \alpha_n (y_n \mathbf{z}_n)$$

$$\alpha_n \text{ from dual solution}$$

$$\mathbf{p}_{\text{LA}} = \sum_{n=1}^{N} \beta_n (y_n \mathbf{z}_n)$$

$$\beta_n \text{ by # mistake corrections}$$

我们发现,二者在形式上是相似的。 $w_{SVM}$ 由fattest hyperplane边界上所有的SV决定, $w_{PLA}$ 由所有当前分类错误的点决定。 $w_{SVM}$ 和 $w_{PLA}$ 都是原始数据点 $y_nz_n$ 的线性组合形式,是原始数据的代表。

#### $\mathbf{w} = \text{linear combination of } y_n \mathbf{z}_n$

- also true for GD/SGD-based LogReg/LinReg when w<sub>0</sub> = 0
- call w 'represented' by data

总结一下,本节课和上节课主要介绍了两种形式的SVM,一种是Primal Hard-Margin SVM,另一种是Dual Hard\_Margin SVM。Primal Hard-Margin SVM有 $\hat{d}+1$ 个参数,有N个限制条件。当 $\hat{d}+1$ 很大时,求解困难。而Dual Hard\_Margin SVM有N个参数,有N+1个限制条件。当数据量N很大时,也同样会增大计算难度。两种形式都能得到w和b,求得fattest hyperplane。通常情况下,如果N不是很大,一般使用Dual SVM来解决问题。

### Primal Hard-Margin SVM

$$\min_{\substack{b,\mathbf{w}}} \quad \frac{1}{2}\mathbf{w}^T\mathbf{w}$$
sub. to 
$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1,$$
for  $n = 1, 2, ..., N$ 

- physical meaning: locate specially-scaled (b, w)

### Dual Hard-Margin SVM

$$\min_{\alpha} \quad \frac{1}{2}\alpha^{T}Q_{D}\alpha - \mathbf{1}^{T}\alpha$$
s.t. 
$$\mathbf{y}^{T}\alpha = 0;$$

$$\alpha_{n} \ge 0 \text{ for } n = 1, \dots, N$$

- N variables,
   N + 1 simple constraints
   —suitable when N small
- physical meaning: locate SVs  $(\mathbf{z}_n, y_n)$  & their  $\alpha_n$

both eventually result in optimal  $(b, \mathbf{w})$  for fattest hyperplane  $g_{\text{SVM}}(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{\Phi}(\mathbf{x}) + b)$ 

这节课提出的Dual SVM的目的是为了避免计算过程中对 $\hat{d}$ 的依赖,而只与N有关。但是,Dual SVM是否真的消除了对 $\hat{d}$ 的依赖呢?其实并没有。因为在计算 $q_{n,m}=y_ny_mz_n^Tz_m$ 的过程中,由z向量引入了 $\hat{d}$ ,实际上复杂度已经隐藏在计算过程中了。所以,我们的目标并没有实现。下一节课我们将继续研究探讨如何消除对 $\hat{d}$ 的依赖。

$$\min_{\alpha} \quad \frac{1}{2}\alpha^{T}\mathbf{Q}_{\mathsf{D}}\alpha - \mathbf{1}^{T}\alpha$$
 subject to 
$$\mathbf{y}^{T}\alpha = 0;$$
 
$$\alpha_{n} \geq 0, \text{ for } n = 1, 2, \dots, N$$

- N variables, N + 1 constraints: no dependence on d?
- $q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m$ : inner product in  $\mathbb{R}^{\tilde{d}}$  — $O(\tilde{d})$  via naïve computation!

#### 总结

本节课主要介绍了SVM的另一种形式: Dual SVM。我们这样做的出发点是为了移除计算过程对 $\hat{d}$ 的依赖。Dual SVM的推导过程是通过引入拉格朗日因子 $\alpha$ ,将SVM转化为新的非条件形式。然后,利用QP,得到最佳解的拉格朗日因子 $\alpha$ 。再通过KKT条件,计算得到对应的w和b。最终求得fattest hyperplane。下一节课,我们将解决Dual SVM计算过程中对 $\hat{d}$ 的依赖问题。

#### 注明:

文章中所有的图片均来自台湾大学林轩田《机器学习技法》课程