林轩田《机器学习技法》课程笔记5 -- Kernel Logistic Regression

作者: 红色石头 公众号: Al有道 (id: redstonewill)

上节课我们主要介绍了Soft-Margin SVM,即如果允许有分类错误的点存在,那么在原来的Hard-Margin SVM中添加新的惩罚因子C,修正原来的公式,得到新的 α_n 值。最终的到的 α_n 有个上界,上界就是C。Soft-Margin SVM权衡了large-margin和error point之前的关系,目的是在尽可能犯更少错误的前提下,得到最大分类边界。本节课将把Soft-Margin SVM和我们之前介绍的Logistic Regression联系起来,研究如何使用 kernel技巧来解决更多的问题。

Soft-Margin SVM as Regularized Model

先复习一下我们已经介绍过的内容,我们最早开始讲了Hard-Margin Primal的数学表达式,然后推导了Hard-Margin Dual形式。后来,为了允许有错误点的存在(或者noise),也为了避免模型过于复杂化,造成过拟合,我们建立了Soft-Margin Primal的数学表达式,并引入了新的参数C作为权衡因子,然后也推导了其Soft-Margin Dual形式。因为Soft-Margin Dual SVM更加灵活、便于调整参数,所以在实际应用中,使用Soft-Margin Dual SVM来解决分类问题的情况更多一些。

Hard-Margin Primal

$$\min_{b,\mathbf{w}} \quad \frac{1}{2}\mathbf{w}^T\mathbf{w}$$
s.t.
$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1$$

Hard-Margin Dual

$$\min_{\alpha} \frac{1}{2} \alpha^{T} Q \alpha - \mathbf{1}^{T} \alpha$$
s.t.
$$\mathbf{y}^{T} \alpha = 0$$

$$0 \le \alpha_{n}$$

Soft-Margin Primal

$$\min_{b,\mathbf{w},\xi} \frac{1}{2}\mathbf{w}^T\mathbf{w} + \frac{C}{C}\sum_{n=1}^{N} \xi_n$$
s.t.
$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1 - \xi_n, \xi_n \ge 0$$

Soft-Margin Dual

$$\min_{\alpha} \frac{1}{2} \alpha^{T} Q \alpha - \mathbf{1}^{T} \alpha$$
s.t.
$$\mathbf{y}^{T} \alpha = 0$$

$$0 \le \alpha_{n} \le C$$

Soft-Margin Dual SVM有两个应用非常广泛的工具包,分别是Libsvm和Liblinear。
Libsvm和Liblinear都是国立台湾大学的Chih-Jen Lin博士开发的,Chih-Jen Lin的个人网站为: Welcome to Chih-Jen Lin's Home Page

下面我们再来回顾一下Soft-Margin SVM的主要内容。我们的出发点是用 ξ_n 来表示 margin violation,即犯错值的大小,没有犯错对应的 $\xi_n=0$ 。然后将有条件问题转化 为对偶dual形式,使用QP来得到最佳化的解。

从另外一个角度来看, ξ_n 描述的是点 (x_n,y_n) 距离 $y_n(w^Tz_n+b)=1$ 的边界有多远。第一种情况是violating margin,即不满足 $y_n(w^Tz_n+b)\geq 1$ 。那么 ξ_n 可表示为: $\xi_n=1-y_n(w^Tz_n+b)>0$ 。第二种情况是not violating margin,即点 (x_n,y_n) 在边界之外,满足 $y_n(w^Tz_n+b)\geq 1$ 的条件,此时 $\xi_n=0$ 。我们可以将两种情况整合到一个表达式中,对任意点:

$$\xi_n = max(1-y_n(w^Tz_n+b),0)$$

上式表明,如果有voilating margin,则 $1-y_n(w^Tz_n+b)>0$, $\xi_n=1-y_n(w^Tz_n+b)$;如果not violating margin,则 $1-y_n(w^Tz_n+b)<0$, $\xi_n=0$ 。整合之后,我们可以把Soft-Margin SVM的最小化问题写成如下形式:

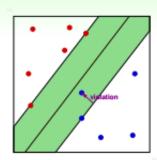
$$rac{1}{2}w^Tw + C\sum_{n=1}^{N}max(1-y_n(w^Tz_n+b),0)$$

经过这种转换之后,表征犯错误值大小的变量 ξ_n 就被消去了,转而由一个 \max 操作代替。

- record 'margin violation' by ξ_n
- · penalize with margin violation

$$\min_{b,\mathbf{w},\xi} \quad \frac{1}{2}\mathbf{w}^T\mathbf{w} + \mathbf{C} \cdot \sum_{n=1}^{N} \xi_n$$

s.t.
$$y_n(\mathbf{w}^T\mathbf{z}_n + b) \ge 1 - \xi_n$$
 and $\xi_n \ge 0$ for all n



on any (b, \mathbf{w}) , $\xi_n = \mathbf{margin \ violation} = \max(1 - y_n(\mathbf{w}^T\mathbf{z}_n + b), 0)$

- (\mathbf{x}_n, y_n) violating margin: $\xi_n = 1 y_n(\mathbf{w}^T \mathbf{z}_n + b)$
- (\mathbf{x}_n, y_n) not violating margin: $\xi_n = 0$

'unconstrained' form of soft-margin SVM:

$$\min_{b,\mathbf{w}} \qquad \frac{1}{2}\mathbf{w}^T\mathbf{w} + \frac{C}{C}\sum_{n=1}^{N} \max(1 - y_n(\mathbf{w}^T\mathbf{z}_n + b), 0)$$

为什么要将把Soft-Margin SVM转换为这种unconstrained form呢?我们再来看一下转换后的形式,其中包含两项,第一项是w的内积,第二项关于y和w,b,z的表达式,似乎有点像一种错误估计 $e\hat{r}r$,则类似这样的形式:

$$min \; rac{1}{2} w^T w + C \sum e \hat{r} r$$

看到这样的形式我们应该很熟悉,因为之前介绍的L2 Regularization中最优化问题的 表达式跟这个是类似的:

$$min \; rac{\lambda}{N} w^T w + rac{1}{N} \sum err$$

$$\min_{b,\mathbf{w}} \quad \frac{1}{2}\mathbf{w}^T\mathbf{w} + C\sum_{n=1}^N \max(1 - y_n(\mathbf{w}^T\mathbf{z}_n + b), 0)$$

familiar? :-)
$$\min \quad \frac{1}{2}\mathbf{w}^T\mathbf{w} + C \sum \widehat{\text{err}}$$

min
$$\frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \frac{1}{N} \sum \text{err}$$

with shorter w, another parameter, and special err

这里提一下,既然unconstrained form SVM与L2 Regularization的形式是一致的,而且L2 Regularization的解法我们之前也介绍过,那么为什么不直接利用这种方法来解决unconstrained form SVM的问题呢?有两个原因。一个是这种无条件的最优化问题无法通过QP解决,即对偶推导和kernel都无法使用;另一个是这种形式中包含的max()项可能造成函数并不是处处可导,这种情况难以用微分方法解决。

我们在第一节课中就介绍过Hard-Margin SVM与Regularization Model是有关系的。 Regularization的目标是最小化 E_{in} ,条件是 $w^Tw \leq C$,而Hard-Margin SVM的目标是最小化 w^Tw ,条件是 $E_{in}=0$,即它们的最小化目标和限制条件是相互对调的。对于L2 Regularization来说,条件和最优化问题结合起来,整体形式写成:

$$rac{\lambda}{N} w^T w + E_{in}$$

而对于Soft-Margin SVM来说,条件和最优化问题结合起来,整体形式写成:

$$rac{1}{2}w^Tw+CN\hat{E_{in}}$$

	minimize	constraint
regularization by constraint	<i>E</i> in	$\mathbf{w}^T\mathbf{w} \leq \mathbf{C}$
hard-margin SVM	$\mathbf{w}^T\mathbf{w}$	$E_{in} = 0$ [and more]
L2 regularization	$\frac{\lambda}{N}\mathbf{w}^T\mathbf{w} + \mathbf{E}_{in}$	
soft-margin SVM	$\frac{1}{2}\mathbf{w}^T\mathbf{w} + CN\widehat{E_{in}}$	

通过对比,我们发现L2 Regularization和Soft-Margin SVM的形式是相同的,两个式子分别包含了参数 λ 和C。Soft-Margin SVM中的large margin对应着L2 Regularization中的short w,也就是都让hyperplanes更简单一些。我们使用特别的 $e\hat{r}r$ 来代表可以容忍犯错误的程度,即soft margin。L2 Regularization中的 λ 和Soft-Margin SVM中的C也是相互对应的, λ 越大,w会越小,Regularization的程度就越大;C越小, \hat{E}_{in} 会越大,相应的margin就越大。所以说增大C,或者减小 λ ,效果是一致的,Large-Margin等同于Regularization,都起到了防止过拟合的作用。

large margin \iff fewer hyperplanes \iff L2 regularization of short \mathbf{w} soft margin \iff special $\widehat{\mathrm{err}}$

larger C or $C \iff$ smaller $\lambda \iff$ less regularization

建立了Regularization和Soft-Margin SVM的关系,接下来我们将尝试看看是否能把 SVM作为一个regularized的模型进行扩展,来解决其它一些问题。

SVM versus Logistic Regression

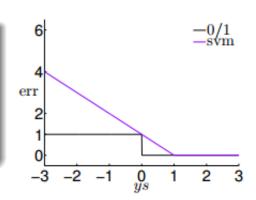
上一小节, 我们已经把Soft-Margin SVM转换成无条件的形式:

$$\min_{b,\mathbf{w}} \frac{1}{2}\mathbf{w}^T\mathbf{w} + C\sum_{n=1}^N \max(1 - y_n(\mathbf{w}^T\mathbf{z}_n + b), 0)$$

上式中第二项的 $max(1-y_n(w^Tz_n+b),0)$ 倍设置为 $e\hat{r}r$ 。下面我们来看看 $e\hat{r}r$ 与之前再二元分类中介绍过的 $err_{0/1}$ 有什么关系。

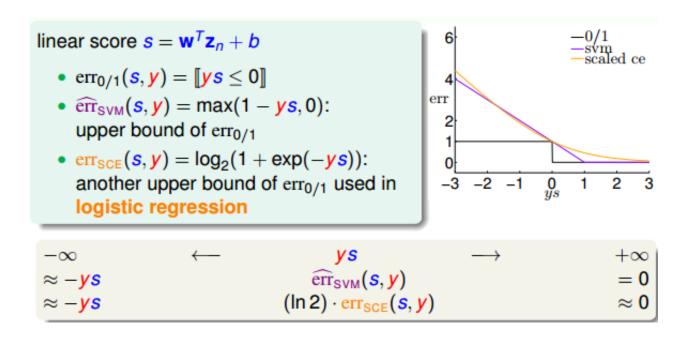
对于 $err_{0/1}$,它的linear score $s=w^Tz_n+b$,当 $ys\geq 0$ 时, $err_{0/1}=0$;当ys<0时, $err_{0/1}=1$,呈阶梯状,如下图所示。而对于 $e\hat{r}r$,当 $ys\geq 0$ 时, $err_{0/1}=0$;当ys<0时, $err_{0/1}=1-ys$,呈折线状,如下图所示,通常把 $e\hat{r}r_{svm}$ 称为hinge error measure。比较两条error曲线,我们发现 $e\hat{r}r_{svm}$ 始终在 $err_{0/1}$ 的上面,则 $e\hat{r}r_{svm}$ 可作为 $err_{0/1}$ 的上界。所以,可以使用 $e\hat{r}r_{svm}$ 来代 替 $err_{0/1}$,解决二元线性分类问题,而且 $e\hat{r}r_{svm}$ 是一个凸函数,使它在最佳化问题中有更好的性质。

linear score $s = \mathbf{w}^T \mathbf{z}_n + b$ • $\operatorname{err}_{0/1}(s, y) = \llbracket ys \le 0 \rrbracket$ • $\widehat{\operatorname{err}}_{\text{SVM}}(s, y) = \max(1 - ys, 0)$: upper bound of $\operatorname{err}_{0/1}$ —often called **hinge error measure**



err_{SVM}: algorithmic error measure by convex upper bound of err_{0/1}

紧接着,我们再来看一下logistic regression中的error function。逻辑回归中, $err_{sce}=log_2(1+exp(-ys))$,当ys=0时, $err_{sce}=1$ 。它的err曲线如下所示。



很明显, err_{sce} 也是 $err_{0/1}$ 的上界,而 err_{sce} 与 $e\hat{r}r_{svm}$ 也是比较相近的。因为当ys趋向正无穷大的时候, err_{sce} 和 $e\hat{r}r_{svm}$ 都趋向于零;当ys趋向负无穷大的时候, err_{sce} 和 $e\hat{r}r_{svm}$ 都趋向于正无穷大。正因为二者的这种相似性,我们可以把SVM看成是L2-regularized logistic regression。

总结一下,我们已经介绍过几种Binary Classification的Linear Models,包括PLA,Logistic Regression和Soft-Margin SVM。PLA是相对简单的一个模型,对应的是 $err_{0/1}$,通过不断修正错误的点来获得最佳分类线。它的优点是简单快速,缺点是只对线性可分的情况有用,线性不可分的情况需要用到pocket算法。Logistic Regression对应的是 err_{sce} ,通常使用GD/SGD算法求解最佳分类线。它的优点是凸函数 err_{sce} 便于最优化求解,而且有regularization作为避免过拟合的保证;缺点是 err_{sce} 作为 $err_{0/1}$ 的上界,当ys很小(负值)时,上界变得更宽松,不利于最优化求解。Soft-Margin SVM对应的是 $e\hat{r}r_{svm}$,通常使用QP求解最佳分类线。它的优点和Logistic Regression一样,凸优化问题计算简单而且分类线比较"粗壮"一些;缺点也和Logistic Regression一样,当ys很小(负值)时,上界变得过于宽松。其实,Logistic Regression和Soft-Margin SVM都是在最佳化 $err_{0/1}$ 的上界而已。

PLA regularized soft-margin **SVM** logistic regression for classification minimize regularized minimize minimize regularized err_{0/1} specially err_{SCE} by GD/SGD/... err_{svm} by QP pros: efficient if pros: 'easy' pros: 'easy' lin. separable optimization & optimization & theoretical regularization guard quarantee cons: loose cons: works only cons: loose bound of err_{0/1} for bound of err_{0/1} for if lin. separable, otherwise very negative ys very negative ys

至此,可以看出,求解regularized logistic regression的问题等同于求解soft-margin SVM的问题。反过来,如果我们求解了一个soft-margin SVM的问题,那这个解能否直接为regularized logistic regression所用?来预测结果是正类的几率是多少,就像regularized logistic regression做的一样。我们下一小节将来解答这个问题。

SVM for Soft Binary Classification

needing pocket

接下来,我们探讨如何将SVM的结果应用在Soft Binary Classification中,得到是正类的概率值。

第一种简单的方法是先得到SVM的解 (b_{svm},w_{svm}) ,然后直接代入到logistic regression中,得到 $g(x)=\theta(w_{svm}^Tx+b_{svm})$ 。这种方法直接使用了SVM和logistic regression的相似性,一般情况下表现还不错。但是,这种形式过于简单,与logistic regression的关联不大,没有使用到logistic regression中好的性质和方法。

第二种简单的方法是同样先得到SVM的解 (b_{svm},w_{svm}) ,然后把 (b_{svm},w_{svm}) 作为 logistic regression的初始值,再进行迭代训练修正,速度比较快,最后,将得到的b和 w代入到g(x)中。这种做法有点显得多此一举,因为并没有比直接使用logistic regression快捷多少。

Naïve Idea 1

- 1 run SVM and get ($b_{\text{SVM}}, \mathbf{w}_{\text{SVM}}$)
- 2 return $g(\mathbf{x}) = \theta(\mathbf{w}_{SVM}^T \mathbf{x} + b_{SVM})$
 - 'direct' use of similarity
 —works reasonably well
 - no LogReg flavor

Naïve Idea 2

- 1 run SVM and get (b_{SVM}, **w**_{SVM})
- 2 run LogReg with $(b_{SVM}, \mathbf{w}_{SVM})$ as \mathbf{w}_0
- **3** return LogReg solution as $g(\mathbf{x})$
 - not really 'easier' than original LogReg
 - SVM flavor (kernel?) lost

这两种方法都没有融合SVM和logistic regression各自的优势,下面构造一个模型,融合了二者的优势。构造的模型g(x)表达式为:

$$g(x) = heta(A \cdot (w_{svm}^T \Phi(x) + b_{svm}) + B)$$

与上述第一种简单方法不同,我们额外增加了放缩因子A和平移因子B。首先利用SVM的解 (b_{svm},w_{svm}) 来构造这个模型,放缩因子A和平移因子B是待定系数。然后再用通用的logistic regression优化算法,通过迭代优化,得到最终的A和B。一般来说,如果 (b_{svm},w_{svm}) 较为合理的话,满足A>0且 $B\approx 0$ 。

$$g(\mathbf{x}) = \theta(\mathbf{A} \cdot (\mathbf{w}_{\text{SVM}}^T \mathbf{\Phi}(\mathbf{x}) + b_{\text{SVM}}) + \mathbf{B})$$

- SVM flavor: fix hyperplane direction by w_{SVM}—kernel applies
- LogReg flavor: fine-tune hyperplane to match maximum likelihood by scaling (A) and shifting (B)
 - often A > 0 if w_{SVM} reasonably good
 - often B ≈ 0 if b_{SVM} reasonably good

那么,新的logistic regression表达式为:

new LogReg Problem:

$$\min_{A,B} \frac{1}{N} \sum_{n=1}^{N} \log \left(1 + \exp \left(-y_n \left(\underbrace{A} \cdot \left(\underbrace{\mathbf{w}_{\text{SVM}}^T \mathbf{\Phi}(\mathbf{x}_n) + b_{\text{SVM}}}_{\mathbf{\Phi}_{\text{SVM}}(\mathbf{x}_n)} \right) + B \right) \right) \right)$$

这个表达式看上去很复杂,其实其中的 (b_{svm}, w_{svm}) 已经在SVM中解出来了,实际上的未知参数只有A和B两个。归纳一下,这种Probabilistic SVM的做法分为三个步骤:

Platt's Model of Probabilistic SVM for Soft Binary Classification

- 1 run SVM on \mathcal{D} to get $(b_{\text{SVM}}, \mathbf{w}_{\text{SVM}})$ [or the equivalent α], and transform \mathcal{D} to $\mathbf{z}'_n = \mathbf{w}_{\text{SVM}}^T \mathbf{\Phi}(\mathbf{x}_n) + b_{\text{SVM}}$
 - -actual model performs this step in a more complicated manner
- 2 run LogReg on $\{(\mathbf{z}'_n, y_n)\}_{n=1}^N$ to get (A, B)—actual model adds some special regularization here
- 3 return $g(\mathbf{x}) = \theta(\mathbf{A} \cdot (\mathbf{w}_{SVM}^T \mathbf{\Phi}(\mathbf{x}) + b_{SVM}) + \mathbf{B})$

这种soft binary classifier方法得到的结果跟直接使用SVM classifier得到的结果可能不一样,这是因为我们引入了系数A和B。一般来说,soft binary classifier效果更好。至于logistic regression的解法,可以选择GD、SGD等等。

Kernel Logistic Regression

上一小节我们介绍的是通过kernel SVM在z空间中求得logistic regression的近似解。如果我们希望直接在z空间中直接求解logistic regression,通过引入kernel,来解决最优化问题,又该怎么做呢?SVM中使用kernel,转化为QP问题,进行求解,但是logistic regression却不是个QP问题,看似好像没有办法利用kernel来解决。

我们先来看看之前介绍的kernel trick为什么会work,kernel trick就是把z空间的内积转换到x空间中比较容易计算的函数。如果w可以表示为z的线性组合,即 $w_* = \sum_{n=1}^N \beta_n z_n$ 的形式,那么乘积项

 $w_*^Tz=\sum_{n=1}^N eta_n z_n^Tz=\sum_{n=1}^N eta_n K(x_n,x)$,即其中包含了z的内积。也就是w可以表示为z的线性组合是kernel trick可以work的关键。

我们之前介绍过SVM、PLA包扩logistic regression都可以表示成z的线性组合,这也提供了一种可能,就是将kernel应用到这些问题中去,简化z空间的计算难度。

SVM $\mathbf{v}_{\text{SVM}} = \sum_{n=1}^{N} (\alpha_n \mathbf{y}_n) \mathbf{z}_n$ $\mathbf{w}_{\text{PLA}} = \sum_{n=1}^{N} (\alpha_n \mathbf{y}_n) \mathbf{z}_n$ $\mathbf{w}_{\text{LOGREG}} = \sum_{n=1}^{N} (\alpha_n \mathbf{y}_n) \mathbf{z}_n$ $\alpha_n \text{ from dual}$ $\mathbf{w}_{\text{DLA}} = \sum_{n=1}^{N} (\alpha_n \mathbf{y}_n) \mathbf{z}_n$ $\alpha_n \text{ by # mistake}$ $\alpha_n \text{ by total SGD}$

有这样一个理论,对于L2-regularized linear model,如果它的最小化问题形式为如下的话,那么最优解 $w_* = \sum_{n=1}^N eta_n z_n$ 。

corrections

moves

solutions

形式。

claim: for any L2-regularized linear model
$$\min_{\mathbf{w}} \quad \frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \frac{1}{N} \sum_{n=1}^N \mathrm{err}(y_n, \mathbf{w}^T \mathbf{z}_n)$$
 optimal $\mathbf{w}_* = \sum_{n=1}^N \beta_n \mathbf{z}_n$.

下面给出简单的证明,假如最优解 $w_*=w_{||}+w_{\perp}$ 。其中, $w_{||}$ 和 w_{\perp} 分别是平行z空间和垂直z空间的部分。我们需要证明的是 $w_{\perp}=0$ 。利用反证法,假如 $w_{\perp}\neq0$,考虑 w_* 与 $w_{||}$ 的比较。第一步先比较最小化问题的第二项: $err(y,w_*^Tz_n)=err(y_n,(w_{||}+w_{\perp})^Tz_n=err(y_n,w_{||}^Tz_n)$,即第二项是相等的。然后第二步比较第一项: $w_*^Tw_*=w_{||}^Tw_{||}+2w_{||}^Tw_{\perp}+w_{\perp}^Tw_{\perp}>w_{||}^Tw_{||}$,即 w_* 对应的L2-regularized linear model值要比 $w_{||}$ 大,这就说明 w_* 并不是最优解,从而证明 w_{\perp} 必然等于零,即 $w_*=\sum_{n=1}^N \beta_n z_n$ 一定成立, w_* 一定可以写成z的线性组合

```
let optimal w<sub>*</sub> = w<sub>||</sub> + w<sub>⊥</sub>, where w<sub>||</sub> ∈ span(z<sub>n</sub>) & w<sub>⊥</sub> ⊥ span(z<sub>n</sub>) —want w<sub>⊥</sub> = 0
what if not? Consider w<sub>||</sub>
of same err as w<sub>*</sub>: err(y<sub>n</sub>, w<sub>*</sub><sup>T</sup>z<sub>n</sub>) = err(y<sub>n</sub>, (w<sub>||</sub> + w<sub>⊥</sub>)<sup>T</sup>z<sub>n</sub>)
of smaller regularizer as w<sub>*</sub>: w<sub>*</sub><sup>T</sup>w<sub>*</sub> = w<sub>||</sub><sup>T</sup>w<sub>||</sub> + 2w<sub>||</sub><sup>T</sup>w<sub>⊥</sub> + w<sub>⊥</sub><sup>T</sup>w<sub>⊥</sub> > w<sub>||</sub><sup>T</sup>w<sub>||</sub>
—w<sub>||</sub> 'more optimal' than w<sub>*</sub> (contradiction!)
```

经过证明和分析,我们得到了结论是任何L2-regularized linear model都可以使用

kernel来解决。

现在,我们来看看如何把kernel应用在L2-regularized logistic regression上。上面我们已经证明了 w_* 一定可以写成z的线性组合形式,即 $w_* = \sum_{n=1}^N \beta_n z_n$ 。那么我们就无需一定求出 w_* ,而只要求出其中的 β_n 就行了。怎么求呢?直接将 $w_* = \sum_{n=1}^N \beta_n z_n$ 代入到L2-regularized logistic regression最小化问题中,得到:

solving L2-regularized logistic regression

$$\min_{\mathbf{w}} \frac{\lambda}{N} \mathbf{w}^{T} \mathbf{w} + \frac{1}{N} \sum_{n=1}^{N} \log \left(1 + \exp \left(-y_{n} \mathbf{w}^{T} \mathbf{z}_{n} \right) \right)$$

yields optimal solution $\mathbf{w}_* = \sum_{n=1}^{N} \beta_n \mathbf{z}_n$

with out loss of generality, can solve for optimal β instead of w

$$\min_{\boldsymbol{\beta}} \frac{\lambda}{N} \sum_{n=1}^{N} \sum_{m=1}^{N} \frac{\beta_{n} \beta_{m} K(\mathbf{x}_{n}, \mathbf{x}_{m})}{N} + \frac{1}{N} \sum_{n=1}^{N} \log \left(1 + \exp \left(-y_{n} \sum_{m=1}^{N} \frac{\beta_{m} K(\mathbf{x}_{m}, \mathbf{x}_{n})}{N} \right) \right)$$

—how? GD/SGD/... for unconstrained optimization

上式中,所有的w项都换成 β_n 来表示了,变成了没有条件限制的最优化问题。我们把这种问题称为kernel logistic regression,即引入kernel,将求w的问题转换为求 β_n 的问题。

从另外一个角度来看Kernel Logistic Regression(KLR):

$$\min_{\boldsymbol{\beta}} \frac{\lambda}{N} \sum_{n=1}^{N} \sum_{m=1}^{N} \frac{\beta_{n} \beta_{m}}{\beta_{m}} K(\mathbf{x}_{n}, \mathbf{x}_{m}) + \frac{1}{N} \sum_{n=1}^{N} \log \left(1 + \exp \left(-y_{n} \sum_{m=1}^{N} \frac{\beta_{m}}{\beta_{m}} K(\mathbf{x}_{m}, \mathbf{x}_{n}) \right) \right)$$

上式中log项里的 $\sum_{m=1}^N eta_m K(x_m,x_n)$ 可以看成是变量eta和 $K(x_m,x_n)$ 的内积。上式第一项中的 $\sum_{n=1}^N \sum_{m=1}^N eta_n eta_m K(x_n,x_m)$ 可以看成是关于eta的正则化项 $eta^T K eta$ 。所以,KLR是eta的线性组合,其中包含了kernel内积项和kernel regularizer。这与SVM是相似的形式。

但值得一提的是,KLR中的 eta_n 与SVM中的 $lpha_n$ 是有区别的。SVM中的 $lpha_n$ 大部分为零,

SV的个数通常是比较少的;而KLR中的 β_n 通常都是非零值。

总结

本节课主要介绍了Kernel Logistic Regression。首先把Soft-Margin SVM解释成 Regularized Model,建立二者之间的联系,其实Soft-Margin SVM就是一个L2-regularization,对应着hinge error messure。然后利用它们之间的相似性,讨论了如何利用SVM的解来得到Soft Binary Classification。方法是先得到SVM的解,再在 logistic regression中引入参数A和B,迭代训练,得到最佳解。最后介绍了Kernel Logistic Regression,证明L2-regularized logistic regression中,最佳解w*一定可以写成z的线性组合形式,从而可以将kernel引入logistic regression中,使用kernel思想在z空间直接求解L2-regularized logistic regression问题。

注明:

文章中所有的图片均来自台湾大学林轩田《机器学习技法》课程